



系统工程理论与实践
Systems Engineering-Theory & Practice
ISSN 1000-6788,CN 11-2267/N

《系统工程理论与实践》网络首发论文

题目：基于隐性因子模型的公募基金业绩分析
作者：周叶童，周炜，刘旭浚，杨金强，李江远
收稿日期：2024-11-11
网络首发日期：2025-09-16
引用格式：周叶童，周炜，刘旭浚，杨金强，李江远. 基于隐性因子模型的公募基金业绩分析[J/OL]. 系统工程理论与实践.
<https://link.cnki.net/urlid/11.2267.N.20250915.1021.014>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于隐性因子模型的公募基金业绩分析

周叶童¹, 周 炜¹, 刘旭浚¹, 杨金强^{1,2}, 李江远^{1,3}

(1. 上海财经大学 金融学院, 上海 200433; 2. 上海国际金融与经济研究院, 上海 200433; 3. 上海财经大学 滴水湖高级金融学院, 上海 201306)

摘 要 合理评价基金业绩是服务国家培育一流投资机构战略需求的重要课题。传统资产定价模型所依赖的显性因子, 难以适应高维特征主导基金业绩的大数据环境。本文采用工具主成分分析法, 从 28 项特征中提取隐性定价因子, 五因子模型对基金及基金组合业绩的解释力在样本内外分别达到 81.85%、99.82% 和 79.53%、99.74%。该模型在整体、时序、截面及相对误差层面均优于传统因子模型及主流机器学习算法, 且对月度和日度回报均具良好解释力。模型定价能力主要源于基金持仓股票的市值、换手率、营业利润、过往表现及基金历史业绩等特征, 同时受通胀、利率、宏观杠杆、流动性和生产不确定性等宏观变量影响。本文建议构建融合大数据的多元化基金业绩评价体系, 提升散户资产配置效率。

关键词 工具主成分分析法; 基金表现; 隐性因子模型; 宏观因素

An IPCA-based latent factor model for mutual fund performance

ZHOU Yetong¹, ZHOU Wei¹, LIU Xujun¹, YANG Jinqiang^{1,2}, LI Jianqyuan^{1,3}

(1. School of Finance, Shanghai University of Finance and Economics, Shanghai 200433, China;

2. Shanghai Institute of International Finance and Economics, Shanghai 200433, China;

3. Dishui Lake Advanced Finance Institute, Shanghai University of Finance and Economics, Shanghai 201306, China)

Abstract Accurately evaluating fund performance is a key issue in supporting the national strategy of cultivating world-class asset management institutions. Traditional asset pricing models, which rely on explicit factors, are insufficient in the era of big data where high-dimensional characteristics dominate fund performance. This paper employs the Instrumented Principal Component Analysis (IPCA) to extract latent pricing factors from 28 fund-related characteristics. The resulting five-factor model achieves explanatory power of 81.85% and 99.82% in-sample,

收稿日期: 2024-11-11

作者简介: 周叶童 (1996-), 女, 汉, 山东烟台人, 博士研究生, 研究方向: 实证资产定价, E-mail: ytzhou@stu.sufe.edu.cn; 周炜 (1999-), 男, 汉, 浙江绍兴人, 博士研究生, 研究方向: 实证资产定价, E-mail: gino.chow@stu.sufe.edu.cn; 刘旭浚 (2000-), 男, 汉, 重庆梁平人, 博士研究生, 研究方向: 实证资产定价, E-mail: liuxujun@stu.sufe.edu.cn; 杨金强 (1983-), 男, 汉, 河北衡水人, 教授, 博士, 研究方向: 动态公司金融理论, 资产定价, E-mail: yang.jinqiang@mail.shufe.edu.cn; 通信作者: 李江远 (1990-), 男, 汉, 河南新乡人, 副教授, 博士, 研究方向: 实证资产定价, 公司金融, E-mail: lijiangyuan@mail.shufe.edu.cn.

基金项目: 国家自然科学基金重大项目 (72394394); 国家自然科学基金专项项目 (72342021); 国家自然科学基金面上项目 (72072108); 国家自然科学基金青年科学基金项目 (72103124); 国家杰出青年科学基金 (72425012); 上海市教育委员会与上海教育发展基金会“晨光计划”项目 (20CG44)

Foundation item: Major Program of National Natural Science Foundation of China (72394394); Special Funds of National Natural Science Foundation of China (72342021); General Program of National Natural Science Foundation of China (72072108); Young Scientists Fund of National Natural Science Foundation of China (72103124); National Science Fund for Distinguished Young Scholars of China (72425012); Chenguang Program of Shanghai Education Development Foundation and Shanghai Municipal Education Commission (20CG44)

中文引用格式: 周叶童, 周炜, 刘旭浚, 等. 基于隐性因子模型的公募基金业绩分析 [J]. 系统工程理论与实践. doi: 10.12011/SETP2024-2890.

英文引用格式: Zhou Y T, Zhou W, Liu X J, et al. An IPCA-based latent factor model for mutual fund performance[J]. Systems Engineering — Theory & Practice. doi: 10.12011/SETP2024-2890.

and 79.53% and 99.74% out-of-sample, for individual funds and fund portfolios, respectively. The model outperforms traditional factor models and mainstream machine learning algorithms in various dimensions. It demonstrates strong explanatory ability for both monthly and daily returns. The pricing power of the latent factors primarily stems from characteristics such as market capitalization, turnover rate, operating profitability, past performance of fund holdings, and historical fund returns, while also being influenced by macroeconomic variables including inflation, interest rates, macro leverage, market liquidity, and industrial production uncertainty. Based on these findings, the paper advocates for the development of a diversified, data-driven fund performance evaluation system to enhance retail investors' asset allocation efficiency.

Keywords IPCA; mutual fund performance; latent factor; macroeconomic factors

1 引言

随着我国资本市场的不断深入发展和改革,公募基金逐渐成为中小家庭资产管理的主要标的。截止到2024年4月,公募基金数量已经达到了11,868只¹,由于不同基金经理能力各异^[1,2],无管理能力者吸引到资金时不仅将增加市场中被无效管理的资金份额,同时将阻碍我国公募基金市场改革的“散户投资机构化”目标,因此,如何有效识别公募基金的投资业绩对于优化散户投资者基金资产配置具有重要意义。

过往研究主要集中于基于单个特征对公募基金业绩进行识别^[2],少有研究对基金各类特征进行联合的系统性检验^[3-5]。本文以隐性因子模型这一独特视角,基于2006年6月至2022年6月中国主动管理股票型公募基金样本,利用Kelly等^[6]所提出的工具主成分分析法(Instrumented Principal Component Analysis, 后称IPCA),从多个基金业绩影响因素中提取了潜在的系统性定价因子。

不同于传统的因子模型,IPCA模型在对因子载荷的动态建模、可解释力、模型简约性以及有效的市场异象识别方面具有明显优势^[6]。首先,IPCA通过将可观测的特征变量作为工具变量来识别和提取潜在的时变因子载荷,突破了传统因子模型中因子载荷静态或外生假设的局限性,直接揭示与预期收益相关的潜在风险因子暴露。相比之下,传统主成分分析(PCA)仅提取数据协方差结构,而IPCA通过引入丰富的特征信息(作为工具变量)为隐性因子载荷提供了经济学理论的支撑,解决了PCA因子缺乏经济含义的缺陷;传统静态因子模型(如CAPM、Fama-French三因子模型、Carhart四因子模型)假设了静态的因子载荷,IPCA则允许载荷随时间动态演化,更贴合市场参与者行为与风险暴露的时变性。其次,IPCA兼具较高的模型解释力和模型简约性。Kelly等^[6]在美国股票市场的研究表明,基于IPCA模型的五个隐性因子对股票横截面平均收益的解释力度显著超越了现有的因子模型²。此外,传统因子模型常存在因子冗余问题^[7],而IPCA的动态建模框架,通过直接在模型中降维的方式,选择最具信息量的特征线性组合,有效降低了模型的复杂度。由此可见,IPCA能够在很大程度上弥补传统因子模型的不足。

相较于机器学习算法,IPCA的核心优势在于其基于经济理论的可解释性。不同于机器学习基于纯数据驱动的“黑箱”挖掘,IPCA通过引入基于经济学理论的特征信息(工具变量),构建的因子载荷本质上为基于特征的投资组合,因此具有明确的经济可解释性。相比之下,机器学习方法(如弹性网络、随机森林等),无论线性还是非线性,其因子提取的过程本质上是统计意义上的数据挖掘。因此,IPCA能够避免机器学习纯数据驱动模式下的“黑箱”问题,确保因子模型在经济学框架下的合理性,从而在资产定价研究和实践中具有重要价值。

本文所提出的单隐性因子模型在样本内对单个基金回报率平均总解释率为75.21%,当隐性因子数量为三和五时,这一解释率分别达到了80.72%和81.85%。无论是与常见的显性因子模型相比

¹封闭式基金和开放式基金的数量分别为1,353和10,515只,市场净值分别为38,249.70亿元和269,527.01亿元。数据详见中国证券投资基金业协会发布的《公募基金市场数据(2024年4月)》: <https://www.amac.org.cn/sjtj/tjbg/gmjj/>。

²除Kelly等^[6]在美国股票市场的研究外,IPCA优异的定价能力在美国债券市场^[8]、美国期权市场^[9],在中国的股市和期权市场都保持稳健^[10,11]。

(Fama-French 三因子模型^[12]、Carhart 四因子模型^[13]与 Liu 等^[14]中国四因子模型), 还是与常见的机器学习模型相比 (弹性网络、偏最小二乘、主成分回归、随机森林与梯度提升树), 本文所识别的隐性因子对基金业绩的解释力度都明显更高. 通过异质性分析发现, 本文所提出的隐性因子对规模更大、过去表现突出 (无论最好还是最坏) 以及投资者情绪更低落的时期对基金业绩的解释力度更强. 同时, 基金持仓中股票的市值、股票换手率、股票的营业利润总资产比、股票过去表现特征和基金过去的超额收益是本文所识别的隐性因子中最重要的五个组成部分. 除此之外, 本文发现能够解释基金业绩的隐性因子与通货膨胀率、国债利率、宏观杠杆率、股债市场的流动性和工业生产不确定性等常见的宏观因素有关.

最后, 本文的主要贡献有以下几个方面:

(1) 基金业绩分析. 本文尝试使用隐性因子模型对公募基金业绩进行了系统性分析, 结果发现, 隐性因子平均而言能够解释绝大部分基金业绩的波动, 该因子的定价能力主要来源于基金持仓股票的市值、股票换手率、股票的营业利润总资产比、股票过去表现特征和基金过去所实现的超额收益. 同时, 本文发现常见的宏观波动, 诸如通货膨胀率、国债利率、宏观杠杆率、股债市场的流动性和工业生产不确定性, 能够解释隐性因子近 10% 的定价能力, 因而本文认为基金业绩同样在较大程度上受到宏观因素的影响.

(2) 高维基金特征处理. 本文创新性地同时考虑了多种能够影响公募基金业绩的潜在因素, 通过 IPCA 模型降维、提取高维数据中的核心潜在成分, 相比于传统的最小二乘法在处理高维数据时容易出现过拟合的问题, IPCA 出色地识别了潜藏于高维特征中的核心定价因子, 同时不会像其他降维算法, 如 LASSO、岭回归 (Ridge) 或弹性网络 (Elastic Net) 等, 丢失未被选中特征所提供的边际信息.

2 文献综述

现有研究在识别能够预测基金未来超额业绩的变量时, 通常基于理论或简单直觉, 其主要基于三个方面:

- (1) **基金自身特征.** 以 DeMiguel 等^[5]为代表的一系列研究从基金本身的特征出发, 发现基金规模^[15,16]、基金费率^[17]、资金净流入^[18]、过往业绩^[1,19,20]、基金排名^[21]、风险水平调整^[22,23]、基金在交易券商网络的中心度^[24]等一系列基金特征能够显著预测基金未来一段时间的超额收益率.
- (2) **基金持仓特征.** Li 和 Rossi^[4]、李斌和雷印如^[25]以及林焯等^[26]发现, 基于公募基金仓位中的股票特征能够选择未来表现更好的公募基金. 常见的仓位特征包括: 行业集中度^[27]、全球化择股的能力^[28]、交易的主动程度^[29,30]、隐性交易^[31,32]、基金持股的网络特征^[33,34]、仓位中股票的彩票特征^[35]、仓位中不被关注到的部分^[3,36]等.
- (3) **基金经理特征.** 除上述因素以外, 部分研究还发现基于基金经理的个人特征也能够预测基金业绩, 包括: 基金经理本科院校^[37]、基金经理的校友网络^[38,39]、基金经理的生日月份^[40]、基金经理的外貌特征^[41]等.

方法上, 近年来, 机器学习方法被广泛应用于收益预测^[42]、因子提取^[6,43,44]及投资组合优化^[45]. 机器学习方法最近也开始应用于中国股票市场中的因子有效性识别、预测模型优化和投资组合构建等方面. 在因子有效性研究方面, 姜富伟等^[46]将主成分分析与弹性网络、LASSO 回归相结合, 在股市中识别出惯性类、交易摩擦类及估值与成长类因子的核心定价功能. 这一发现在李斌等^[47]的研究中得以验证, 其通过 12 种机器学习算法验证了交易摩擦类因子在 A 股的显著预测能力. 毛杰等^[48]进一步采用双重选择 LASSO 模型, 对 85 个股票市场的定价因子进行了边际有效性检验, 为因子筛选提供了新方法. Leippold 等^[49]则采用多种机器学习算法, 揭示了流动性指标在中国股市中的核心解释力. 在模型构建技术层面, 马甜等^[50]基于 148 个企业特征构建了因子大数据集, 采用生成式对抗网络 (GAN) 建立深度学习预测框架, 在收益预测精度与投资组合绩效方面实现显著突破. 倪宣明等^[51]将最大化夏普率原则引入主成分分析, 提出了一种均值方差有效的稀疏主成分分析算法, 该算法提取的因子能够优化对

资产的定价能力. 李斌和屠雪永^[52] 则提出了一个基于机器学习与资产特征的投资组合选择框架, 基于此框架提出的投资策略可以捕捉高维特征中的增量信息, 并挖掘出资产特征与投资组合权重间的线性或非线性关系, 从而构建绩效更优的投资组合.

综合上述分析, 目前机器学习方法在中国市场的应用主要集中于股票市场, 少有文献基于基金的多个特征联合检验基金业绩. DeMiguel 等^[5] 利用机器学习的方法, 从大量的基金特征中提取了能够预测基金未来业绩的因素, 而 Li 和 Rossi^[4]、李斌和雷印如^[25] 同样利用机器学习的算法, 检验了基金的股票持仓特征能够显著预测基金未来的收益. 但上述研究都仅基于部分特征检验基金业绩, 并未联合考虑基金特征与基金持仓股票特征, 这导致其对基金业绩的评估并不全面, 同时无法识别两种特征中的主导因素.

与本文类似的是, Kaniel 等^[3] 同时基于基金自身特征、持仓特征与宏观因素来预测基金未来业绩, 发现了多种因素能够联合预测基金未来业绩, 但他们在美国公募基金市场中根据神经网络方法形成的基金多空组合对投资者而言并不是可交易的 (通过非线性的方法来形成组合), 同时, 受限于神经网络算法, 他们对基金业绩的解释能力并没有清晰的经济学含义. 本文创新性地在市场中通过 IPCA、为投资者提供了可交易的投资组合, 并发现该因子与宏观增长紧密相关. 本文能够为中小家庭的资金配置提供一定程度的参考, 对中国公募基金市场的发展具有一定的现实意义.

3 数据来源与样本

3.1 数据来源

3.1.1 公募基金

本文从 RESSET 数据库选取了自 2006 年 6 月至 2022 年 8 月所有主动管理股票型基金和重点投资于股票市场的混合型基金数据. 参考林兢等^[54,55], 本文基金样本的筛选遵循以下标准: (1) 基金在 RESSET 数据库中的标识为“主动型”; (2) 基金在 WIND 数据库中被标记为“股票型”或“偏股混合型”; (3) 基金在 CSMAR 数据库中非 ETF、QDII 和指数型基金, 且主动管理标识不为否; (4) 基金在股票市场的投资不低于总资产的 50%; (5) 基金成立时间不少于 1 年. 本文限制了样本内基金的总资产大于 2 千万人民币. 同时, 为避免 Evans^[56] 所提出的孵化偏差, 本文删除了基金标识创立以前所存在的数据. 此外, 本文从 RESSET 数据库获取了公募基金的持仓情况、发行时间、基金规模、基金收益率、管理费率等基金特征. 最后, 本文样本中共有 2897 只主动管理股票型基金. 基金特征变量的具体定义见附录 A.1.

3.1.2 股票特征

同时, 本文从 CSMAR 数据库中选取了 2003 年 6 月至 2022 年 6 月所有沪深两市上市股票的财报数据和交易数据, 并排除了其中的银行和非银金融行业 (申万宏源行业分类代码的前两位数字为 48/49) 上市公司³. Fama-French^[57] 六因子 (FF6) 及无风险利率 (一年期定存利率) 数据同样来自于 CSMAR 数据库. Liu 等^[14] 的中国四因子数据来自 Robert Stambaugh 教授的个人网站⁴. 参考 Liu 等^[14] 和 Du 等^[58], 本文在股票样本中剔除以下观测: (1) 上市时间不足六个月; (2) 过去 12 个月内其交易日少于 120 天, 或过去一个月内其交易日少于 10 天. 为了避免受到具有壳价值观测的影响, 本文进一步在截面上剔除了公司市值处于最低 30% 的股票⁵. 股票特征的具体定义见附录 A.2.

³除此之外, 本文还考虑了使用证监会的行业分类标准, 在该标准下, 上市公司被分为 29 或 84 个行业. Chen 等^[59] 认为, 在构建行业层面变量时, 该分类标准可能会导致行业内公司数量不足.

⁴感谢原作者们的慷慨分享, 数据请参考<https://finance.wharton.upenn.edu/~stambaugh/>.

⁵20 世纪 90 年代, 中国股市面临上市公司数量少及会计准则可靠性不足的问题, 因此大多数关注中国股市的研究都将样本限制在 2000 年后^[14,60]. 2002 年, 中国上市公司首次被要求披露季报, 相应地, 中国第一个采用季度财务数据构建的变量出现在 2003 年.

3.1.3 宏观变量

参考周炜等^[61], 本文从 CSMAR 和 RESSET 数据库选取了 28 个影响股票和债券市场的宏观特征以探究隐性因子定价能力的来源, 包括基本的宏观经济特征以及与市场风险相关的特征. 为保证数据频率一致, 本文所涉及特征均为月度变量. 样本时间从 2004 年 1 月至 2022 年 6 月. 宏观变量的具体定义见附录 A.3.

3.2 描述性统计

表1展示了本文所用基金特征的描述性统计⁶. 可以看出, 样本中基金的已实现异常回报 (ReaAlpha) 的分布基本基于 50 分位数呈现左右对称状态, 且 50 分位数和平均值均大于 0, 说明样本中大部分观察值可实现正的异常回报; 然而已实现异常回报 t 值 (t_alpha) 在 75 分位数处仍不显著 (t 值仅为 1.27), 说明仅有少部分基金能够实现统计意义上显著的正收益, 这与美国市场中的结论类似^[62,63]. 与之相对的是, 市场风险溢价因子 t 值 (t_mktrf) 在 50 分位数处呈现出统计意义上的正向显著 (t 值为 2.05), 说明至少有一半的基金具有显著的市场风险暴露. 另外, 绝大部分的基金流量 (QuarFlow) 小于 0, 说明从整体上来说, 基金呈现资金净流出状态. 值得注意的是, 基金费率 (ExpRatio) 的平均值为 1.64% 而标准差却高达 0.95%, 说明我国公募基金平均来说费用支出水平较高且存在较大差异.

最后, 根据 Kelly 等^[6], 本文在实证分析之前在截面上对基金的各项特征变量统一进行了标准化处理. 具体而言, 假设截面上有 N 个基金样本, 首先将样本按照原始特征大小进行排序, 记录排序值 $0, \dots, N-1$; 接着将该排序值除以 $N-1$ 并减去 0.5; 如此所有的基金特征便被标准化到了 $[-0.5, 0.5]$ 的区间内. 对基金特征进行标准化处理主要基于两个理由: 第一, 排除极端值的影响. 截面上的特征差异是基金收益和模型估计的重要影响因素, 通过关注特征排序而不是绝对大小, 可以确保 IPCA 结果对特征极端值变化不敏感. 第二, 确保特征投资组合的资产权重之和为 0. IPCA 模型的另一解释路径是基于特征矩阵构建的投资组合, 标准化程序能够使投资组合在各资产的权重之和为 0, 与资产定价研究中常见的多空组合 (long-short portfolio) 相类似.

表 1 描述性统计

变量	观测数	平均值	标准差	分位数		
				p25	p50	p75
ReaAlpha (%)	128 249	0.70	2.21	-0.29	0.61	1.54
t_mktrf	128 249	2.09	1.83	0.97	2.05	3.20
t_smb	128 249	0.48	1.68	-0.45	0.28	1.18
t_hml	128 249	-0.32	1.51	-1.06	-0.31	0.40
t_rmw	128 249	-0.53	1.63	-1.52	-0.65	0.35
t_cma	128 249	-0.39	1.40	-1.05	-0.32	0.34
t_umd	128 249	0.81	1.87	-0.37	0.68	1.90
t_alpha	128 249	0.51	1.57	-0.29	0.53	1.27
FundAge	146 685	66.52	46.63	30.00	54.00	90.00
TNA ($\times 10^9$)	139 924	1.70	2.77	0.18	0.63	1.96
QuartFlow (%)	131 279	4.25	62.56	-10.92	-3.68	0.77
FlowVol (%)	89 707	31.29	55.01	7.40	14.38	30.02
ExpRatio (%)	133 285	1.64	0.95	1.10	1.41	1.91
ValAdd ($\times 10^6$)	127 494	21.73	102.72	-0.05	3.24	16.51

4 实证模型

本章详细介绍了本文所使用的核心实证模型, 工具主成分分析法. 本章结构如下: 4.1 节首先介绍了静态因子模型, 该模型为工具主成分分析等一系列动态因子模型奠定了理论基础. 4.2 节引出本文核心

⁶出于篇幅考虑, 本文将股票特征及宏观变量的描述性统计汇报在附录 B 中.

实证模型工具主成分分析法的具体构建. 4.3 节则提供了常见显性因子模型作为比较的基准. 最后, 在 4.4 节中介绍了衡量本文所使用模型优良程度的指标.

4.1 静态因子模型

基于 Ross^[64] 的套利定价理论 (APT), Connor 和 Korajczyk^[65] 提出的静态因子模型 (Static Factor Model) 认为资产收益率由少数系统性风险因子所驱动. 与传统多因子模型依赖经济理论预先定义因子 (如市场、规模等) 不同, 静态因子模型摒弃了主观假设, 而是通过主成分分析 (PCA) 从资产收益中直接提取统计意义上的共同因子. 如式(1)所示, 静态因子模型设定中假设因子 f_t 的协方差矩阵在样本期内保持稳定, 且因子载荷 β_i 为不随时间变化的静态参数. 运用显性因子模型拟合资产收益的过程如下: (1) 因子提取: 对资产收益的协方差矩阵进行特征值分解, 保留前 K 个主成分 (对应最大特征值的特征向量) 作为因子载荷矩阵 β_i ; (2) 因子收益估计: 通过最小化残差平方和 (式(2)) 求解因子收益时序, 即 $f_t = (\beta'\beta)^{-1}\beta'r_t$; (3) 模型验证: 计算样本内拟合优度 R^2 , 量化前 K 个因子对资产收益变动的解释能力.

$$r_t = \beta_i f_t + \epsilon_t. \quad (1)$$

$$\min_{\beta, f} \sum_{t=1}^T (r_t - \beta f_t)' (r_t - \beta f_t). \quad (2)$$

显性因子模型无法捕捉风险敏感度的动态变化, 由数据驱动的纯统计因子缺乏经济学理论的支撑, 而工具主成分分析法旨在克服这些缺陷, 在时变的因子载荷假设下, 提取具有经济学含义的因子载荷.

4.2 工具主成分分析法

Kelly 等^[6,8] 对时变的因子载荷建模, 利用无需提前指定形式的隐性因子对资产收益率进行系统性分析. 该模型将可观测的资产特征作为时变因子载荷的工具变量, 从高维度资产特征信息中提取低维的因子载荷结构, 实现对隐性因子的刻画. 具体而言, 假设资产数目为 N , 时期为 $t = 1, \dots, T$, 资产 i 在 $t+1$ 时期的超额收益 $r_{i,t+1}$ 可以表示为以下形式:

$$r_{i,t+1} = \alpha_{i,t} + \beta_{i,t} f_{t+1} + \epsilon_{i,t+1}. \quad (3)$$

$$\begin{aligned} \alpha_{i,t} &= z_{i,t}' \Gamma_\alpha + \nu_{\alpha,i,t}, \\ \beta_{i,t} &= z_{i,t}' \Gamma_\beta + \nu_{\beta,i,t}, \end{aligned} \quad (4)$$

其中, f_{t+1} 为 $K \times 1$ 维度的资产因子. $\alpha_{i,t}$ 和 $\beta_{i,t}$ 分别表示因子模型的动态截距项和风险载荷矩阵, 均由 $L \times 1$ 维度的资产特征向量 $z_{i,t}'$ 所解释. 参数矩阵 Γ_α 和 Γ_β 维度分别为 $L \times 1$ 和 $L \times K$, 规定从高维度的资产特征信息到低维风险载荷的线性映射参数. 另外, IPCA 模型要求用于估计的可观测资产特征数量 L 远大于隐性因子个数 K .

将模型写成向量形式, 可以得到:

$$r_{t+1} = Z_t \tilde{\Gamma} \tilde{f}_{t+1} + \epsilon_{t+1}^*, \quad (5)$$

其中, $\tilde{\Gamma} = [\Gamma_\alpha, \Gamma_\beta]$, $\tilde{f}_{t+1} = [1, f_{t+1}']'$, $\epsilon_{t+1}^* = \epsilon_{t+1} + \nu_{\alpha,t} + \nu_{\beta,t} f_{t+1}$. r_{t+1} 为 $N \times 1$ 的资产收益向量, Z_t 为 $N \times L$ 的资产特征矩阵, 每行对应单个资产的 L 个特征. 通过最小化式(5)的残差平方和, 可以得到 $\tilde{f}_{t+1}$ 和 $\tilde{\Gamma}$ 满足的一阶条件:

$$\begin{aligned} \min_{\Gamma, F} \sum_{t=1}^{T-1} (r_{t+1} - Z_t \tilde{\Gamma} \tilde{f}_{t+1})' (r_{t+1} - Z_t \tilde{\Gamma} \tilde{f}_{t+1}). \\ \hat{f}_{t+1} = \left(\hat{\Gamma}_\beta' Z_t' Z_t \hat{\Gamma}_\beta \right)^{-1} \hat{\Gamma}_\beta' Z_t' (r_{t+1} - Z_t \hat{\Gamma}_\alpha), \quad \forall t. \end{aligned} \quad (6)$$

$$\text{vec}(\hat{\Gamma}') = \left(\sum_{t=1}^{T-1} Z_t' Z_t \otimes \hat{f}_{t+1} \hat{f}_{t+1}' \right)^{-1} \left(\sum_{t=1}^{T-1} [Z_t \otimes \hat{f}_{t+1}]' r_{t+1} \right). \quad (7)$$

可以注意到式(6)是在截面上将 $r_{t+1} - \alpha_t$ 对 β_t 做回归的系数, 类似于 Fama-MacBeth 回归; 式(7)是在时间序列上 r_{t+1} 对 $Z_t \otimes \hat{f}_{t+1}$ 做回归的系数. 由于不存在解析解, Kelly 等^[6] 采用交替最小二乘法 (Alternating Least Squares, ALS) 求解待估矩阵数值.

与多数隐性因子模型类似, IPCA 模型需要给定额外的假设条件才能唯一确定参数矩阵 Γ_α 、 Γ_β 和因子矩阵 f_{t+1} . 在不给定假设的前提下, 模型 $\tilde{\Gamma} \tilde{f}_t$ 与模型 $\tilde{\Gamma} R R^{-1} \tilde{f}_t$ 相同 (只要 R 为旋转矩阵). 因此, 本文额外要求 $\Gamma_\alpha' \Gamma_\beta = \mathbf{0}_{1 \times K}$; $\Gamma_\beta' \Gamma_\beta$ 为单位矩阵; 因子矩阵的协方差矩阵为对角阵, 且对角线元素递减; 因子矩阵在时间序列上的均值为非负. 值得注意的是, 这些假设条件不会改变 IPCA 模型的经济意义, 而仅仅是起到确定唯一解的作用.

IPCA 模型与基于资产特征构建的投资组合也紧密相关. 定义 t 期 $N \times L$ 的资产特征矩阵为 Z_t , 则基于此构建 $t+1$ 时刻的特征投资组合为:

$$x_{t+1} = \frac{Z_t' r_{t+1}}{N_{t+1}}, \quad (8)$$

其中, N_{t+1} 表示 $t+1$ 时刻的资产数量. 投资组合 x_{t+1} 的维度为 $L \times 1$, l 行元素 $x_{l,t+1}$ 表示以 Z_t 中第 l 个特征作为权重构建的投资组合收益, 每个组合包含 N_{t+1} 个资产.

4.3 基准显性因子模型及其估计

本文考虑了在公募基金市场中常见的显性因子模型作为本文所使用的 IPCA 模型的参考基准.

MKT 模型. 作为基准模型, 本文选择 Sharpe^[66] 提出的 CAPM 模型作为第一个显性因子模型参照标准. CAPM 模型仅包含一个显性因子, 即市场因子 (MKT), 是衡量资产定价模型是否有效的一个重要参考基准.

FC4 模型. Carhart^[13] 发现, 包含市场因子 (MKT)、规模因子 (SMB)、账面市值比因子 (HML) 以及动量因子 (UMD) 的四因子模型 (FC4) 对公募基金回报率具有优异的解释能力. 因此, 本文选择 FC4 模型作为第二个显性因子模型.

CH4 模型. Liu 等^[14] 首先基于中国市场特点对 Fama-French^[12] 三因子模型 (FF3) 进行调整, 构造了更加适合中国市场的中国三因子模型 (CH3), 包括市场因子 (MKT)、规模因子 (SMB) 以及价值因子 (VMG), 然后基于异常换手率指标引入情绪因子 (PMO) 共同构成了中国四因子模型 (CH4) 以进一步提高模型的解释力度. 因此, 本文以 CH4 模型作为第三个显性因子模型.

参考 Kelly 等^[6,8], 为了使现有的因子模型和 IPCA 的隐性因子模型可以互相比, 本文尝试在 IPCA 的框架下估计可观测的因子模型. 将因子矩阵作为已知, 进而通过一阶条件估计参数矩阵 Γ_β (见式6).

4.4 拟合优度和相对定价误差

根据 Kelly 等^[6,8], 本文分别从单个基金和基金组合的角度出发, 构建了面板、时序、截面三个维度的拟合优度指标, 以及相对定价误差指标, 以综合衡量 IPCA 模型对公募基金收益率的解释力度.

整体 R^2 . 与常见的拟合优度指标 R^2 类似, 定义单个基金层面的整体 R^2 如下:

$$\text{Total } R^2 = 1 - \frac{\sum_{i,t} \left(r_{i,t+1} - z_{i,t}' (\hat{\Gamma}_\alpha + \hat{\Gamma}_\beta \hat{f}_{t+1}) \right)^2}{\sum_{i,t} r_{i,t+1}^2}.$$

相应地, 式(8)所代表的特征投资组合的整体 R^2 定义为:

$$\text{Total } R^2 = 1 - \frac{\sum_{l,t} \left(x_{l,t+1} - z_{l,t}' z_{l,t} (\hat{\Gamma}_\alpha + \hat{\Gamma}_\beta \hat{f}_{t+1}) \right)^2}{\sum_{l,t} x_{l,t+1}^2}.$$

时序 R^2 . 定义单个资产 i 层面上的拟合优度为 $R_i^2 = 1 - \frac{\sum_t (r_{i,t+1} - \hat{\beta}'_{i,t} \hat{f}_{t+1})^2}{\sum_t r_{i,t+1}^2}$. 由于每个截面上存续的基金数量不同, 因而本文以每个基金在时点上的观测数 T_i 作为权重, 计算了时序上加权平均的拟合优度, 得到时序 R^2 :

$$\text{Time-Series } R^2 = \frac{1}{\sum_i T_i} \sum_i T_i R_i^2.$$

截面 R^2 . 在 $t+1$ 时点对 t 时点的资产回报做 Fama-MacBeth 截面回归得到 (条件) 贝塔的 R^2 , 即 $R_{t+1}^2 = 1 - \frac{\sum_i (r_{i,t+1} - \hat{\beta}'_{i,t} \hat{f}_{t+1})^2}{\sum_i r_{i,t+1}^2}$. 对每个时期的截面 R^2 取时序平均得到截面 R^2 :

$$\text{Cross-Section } R^2 = \frac{1}{T} \sum_t R_t^2.$$

相对定价误差. 本文定义相对定价误差为定价误差平方和除以平均收益平方和:

$$\text{Relative Pricing Error} = \frac{\sum_i \alpha_i^2}{\sum_i \bar{r}_i^2},$$

其中, 令 $\alpha_i = \frac{1}{T_i} \sum_t (r_{i,t+1} - \hat{\beta}'_{i,t} \hat{f}_{t+1})$ 为资产 i 的平均时序误差, $\bar{r}_i = \frac{1}{T_i} \sum_t r_{i,t+1}$ 为资产 i 的时序平均超额收益.

5 实证结果

5.1 IPCA 的表现

本文包含了 28 个与基金业绩有关的基金特征作为 IPCA 模型中因子载荷的工具变量, 包括 DeMiguel 等^[5] 文中所涉及的 14 个基金特征以及 Li 和 Rossi^[4] 文中所涉及的最重要的 10 个基金持仓特征和 4 个常见的财务指标特征⁷. 本文最终选取的特征数量与其他应用 IPCA 模型的研究中使用的特征数量近似^[6,8]. 同样地, 本文参考 Kelly 等^[6,8] 的方法, 通过更快收敛的交替最小二乘法 (ALS) 得到 IPCA 模型的参数估计值.

样本内. 样本内拟合的核心是通过历史数据估计 IPCA 模型参数, 构建因子暴露与收益的映射关系. 具体地, 本文首先对基金收益率矩阵和工具变量矩阵进行标准化处理, 以保证因子载荷的可比性; 然后, 采用交替最小二乘法 (ALS) 进行迭代优化, 求解 IPCA 模型因子载荷矩阵与因子矩阵的数值解. 表2中的面板 A 和面板 B 分别展示了不包含和包含截距项的 IPCA 模型对于基金未来业绩的拟合程度. 在不包含截距项的情况下 (面板 A), 单因子的 IPCA 模型 ($K=1$) 对基金和基金组合收益总体变动的解释程度分别达到了 75.21% 和 97.77%, 而相对的不能解释部分, 即相对定价误差分别为 34.38% 和 0.65%. 随着模型中因子个数的增加, 模型的拟合优度逐渐上升而相对定价误差逐渐下降, IPCA 五因子模型对基金和基金组合收益的总体解释力度上升到了 81.85% 和 99.82%, 而相对定价误差下降到 27.00% 和 0.21%. 面板 B 初步验证了采用包含截距项的 IPCA 模型并不会显著降低其解释力度. 为正式检验模型中是否包含截距项对结果的影响, 本文在面板 C 中用自举检验法 (Bootstrap Test) 检验了 IPCA 模型的截距项是否显著异于零 ($H_0: \Gamma_\alpha = 0$). 面板 C 中各 p 值都远大于 0.1, 这说明即便在 10% 的置信水平下, 依然可以认为模型中的截距项与零无异, 即, IPCA 模型所识别的隐性因子可以在很大程度上解释基金业绩的波动, 该框架下基金并不存在统计意义上显著的异常回报.

⁷ 14 个基金特征: 已实现异常回报、市场风险溢价因子 t 值、市值因子 t 值、账面市值比因子 t 值、盈利能力因子 t 值、投资模式因子 t 值、动量因子 t 值、已实现异常回报 t 值、基金成立月数、总资产净值、基金流量、流量波动率、基金费率和附加价值; 10 个基金持仓特征和 4 个常见的财务指标特征: 6 个月/12 个月/36 个月动量、贝塔系数、异质波动率、平均交易量、平均换手率、总市值、总资产增长率、账面市值比对数、营业利润总资产比、应计利润、净资产收益率和行业调整市值. 由于 Li 和 Rossi^[4] 所展示的最重要的 10 个基金特征均为市场交易特征, 为避免选择偏误, 本文加入了四个在中国市场具有代表性的财务指标特征作为补充, 以上特征的具体构造方法详见附录 A.

表 2 IPCA 模型表现: 样本内

	因子个数(K)				
	1	2	3	4	5
面板 A: $\Gamma_{\alpha} = 0$					
面板 A1: 单个基金					
Total R^2	75.21	78.87	80.72	81.47	81.85
Time-Series R^2	64.96	76.53	78.48	79.54	79.98
Cross-Section R^2	60.75	64.73	67.73	68.98	69.51
Relative Pricing Error	34.38	29.08	28.57	28.14	27.00
面板 A2: 管理投资组合					
Total R^2	97.77	99.05	99.63	99.77	99.82
Time-Series R^2	20.26	59.55	79.53	85.24	87.65
Cross-Section R^2	86.51	93.82	97.66	98.69	98.86
Relative Pricing Error	0.65	0.55	0.43	0.39	0.21
面板 B: $\Gamma_{\alpha} \neq 0$					
面板 B1: 单个基金					
Total R^2	75.34	78.95	80.78	81.53	81.90
Time-Series R^2	65.62	76.59	78.50	79.52	79.93
Cross-Section R^2	60.94	64.96	67.91	69.14	69.63
Relative Pricing Error	31.51	28.23	27.86	27.09	26.23
面板 B2: 管理投资组合					
Total R^2	97.81	99.07	99.64	99.78	99.82
Time-Series R^2	21.84	60.58	80.13	85.79	87.80
Cross-Section R^2	87.13	94.23	97.82	98.82	98.94
Relative Pricing Error	0.30	0.09	0.06	0.04	0.02
面板 C: 自举检验 (Bootstrap Test, $H_0: \Gamma_{\alpha} = 0$)					
p 值	0.72	0.86	0.86	0.51	0.26

样本外. 为避免训练参数时出现前瞻误差 (look-ahead bias), 本文使用扩展窗口 (expanding window) 进一步检验了 IPCA 模型在样本外的预测能力, 并将样本外的拟合结果汇报在表3中. 具体而言, 本文将初始窗口长度设置为总样本期的一半, 由于在计算基金的超额回报时需用到过去 36 个月的回报率, 且本文样本开始于 2006 年 6 月, 因此样本外测试的初始窗口实际为 2008 年 4 月至 2015 年 4 月. 在初始窗口后的每个月 t , 首先以 1 至 t 期作为样本窗口估计参数矩阵 $\hat{\Gamma}_{\beta,t}$, 基于此, 计算 $t+1$ 期的因子矩阵 $\hat{f}_{t+1} = (\hat{\Gamma}'_{\beta,t} Z'_t Z_t \hat{\Gamma}_{\beta,t})^{-1} \hat{\Gamma}'_{\beta,t} Z'_t r_{t+1}$, 最后, 通过比较 r_{t+1} 和 $Z_t \hat{\Gamma}_{\beta,t} \hat{f}_{t+1}$ 、 x_{t+1} 和 $Z'_t Z_t \hat{\Gamma}_{\beta,t} \hat{f}_{t+1}$ 分别计算模型在单个基金及基金组合层面的样本外拟合优度 R^2 以及相对定价误差. 单因子的 IPCA 模型对基金和基金组合收益的整体拟合优度分别达到 72.72% 和 97.16%, 相对定价误差分别为 37.55% 和 1.99%, 均接近其在样本内的数值; 类似地, 多个因子 IPCA 模型 ($K = 2, 3, 4, 5$) 的整体、时序和截面拟合优度均逐渐上升而相对定价误差逐渐下降, 进一步优化了拟合程度. 由此可见, IPCA 模型在样本外仍然保持着优异的解能力, 进一步说明其在预测基金收益方面具有准确性和稳健性.

因子收益率. 图1展示了五个隐性 IPCA 因子的累计收益率. 尽管因子 1 和因子 2 在样本初期 (2008 年全球金融危机后期) 表现出了负收益, 因子 3、因子 4 和因子 5 却从样本初期就实现了正收益, 且到了 2013 年之后, 所有因子均实现了正的累计收益. 值得注意的是, 相比于因子 1 和因子 2, 因子 3、4、5 的整体波动更小, 暗示着因子 3、4、5 可能与一些波动相对于单个特征组合收益率更小的因素有关, 本文将在 5.4 节中进一步讨论. 进一步地, 可以通过 IPCA 模型进行因子识别, 然后基于识别出的各个因子分别创建投资组合, 表4展示了这些投资组合在样本外的收益与风险特征. 可以看出, 通过 IPCA 模型构建的投资组合至少可以实现 2.87% 的预期收益 (ER) 和 0.23 的夏普比率 (SR), 最高则可以实

表 3 IPCA 模型表现: 样本外

	因子个数(K)				
	1	2	3	4	5
面板 A: 单个基金					
Total R ²	72.72	75.70	78.48	79.26	79.53
Time-Series R ²	59.66	72.84	75.39	76.68	76.80
Cross-Section R ²	51.75	56.53	60.15	61.05	61.64
Relative Pricing Error	37.55	34.17	32.55	31.98	32.00
面板 B: 管理投资组合					
Total R ²	97.16	98.41	99.51	99.68	99.74
Time-Series R ²	21.36	48.24	77.48	82.17	84.76
Cross-Section R ²	82.01	91.62	96.80	97.35	97.89
Relative Pricing Error	1.99	1.81	1.00	0.95	0.78

现 10.93% 的预期收益和 0.89 的夏普比率; 另外, 该投资组合还能产生基于经典资产定价模型的异常回报 (α^{CAPM} 、 α^{FC4} 、 α^{CH4}).




图 1 IPCA 因子累积收益率

以上分析表明, 本文所用 IPCA 模型能够出色地解释基金的未来业绩, 通过 IPCA 模型识别出的因子构建投资组合则能够实现显著的预期收益和异常回报.

5.2 IPCA 与常见显性因子模型对比

经典的显性因子模型被证实能够在很大程度上解释基金业绩的波动^[13,14]. 为了探究 IPCA 模型在预测基金业绩方面是否优于传统的因子模型, 本文在实证检验中选取了三个显性因子模型作为 IPCA 模型拟合基金业绩的比较基准, 其中 Carhart^[13] 的四因子模型 FC4 的原始构建是基于公募基金业绩持续性的研究, 且被广泛应用于基金业绩的评估中^[62,63,67]. 本文在表5中对比了 IPCA 模型与三个经典显性因子模型的表现, 在单因子层面, IPCA 模型 ($K = 1$) 在各个层面上的拟合优度都优于 CAPM, 即, 拥有更高的 R^2 和更小的相对定价误差; 对于四因子模型而言, IPCA 模型 ($K = 4$) 同样在各个维度上均优于 Carhart^[13] 基金四因子模型和 Liu 等^[14] 中国四因子模型. 这一结论无论对于单个基金 (面板

表 4 IPCA 因子表现: 样本外

	因子个数(K)				
	1	2	3	4	5
ER(%)	3.18	3.33	2.87	6.86	10.93
Vol(%)	9.31	9.96	12.50	11.64	12.29
Skew	-0.61	-0.35	-0.52	0.55	0.82
Kurt	2.11	0.24	0.64	0.77	2.71
SR	0.34	0.33	0.23	0.59	0.89
α^{CAPM}	4.13	4.04	3.98	8.31	13.14
	(3.58)	(1.74)	(1.02)	(1.98)	(3.00)
α^{FC4}	2.76	1.89	0.08	5.20	8.68
	(4.20)	(1.27)	(0.03)	(1.38)	(2.11)
α^{CH4}	6.79	8.45	6.59	10.32	13.02
	(5.94)	(4.11)	(1.62)	(2.29)	(2.82)

A) 还是管理投资组合 (面板 B) 都成立. 由此可见, IPCA 模型在解释基金未来收益方面要优于传统的显性因子模型.

表 5 IPCA 与显性因子模型表现对比

	MKT	FC4	CH4	IPCA (K=1)	IPCA (K=4)
面板 A: 单个基金					
Total R ²	59.81	74.35	66.52	75.21	81.47
Time-Series R ²	61.05	74.34	66.57	64.96	79.54
Cross-Section R ²	36.86	53.01	38.54	60.75	68.98
Relative Pricing Error	48.76	36.00	62.16	34.38	28.14
面板 B: 管理投资组合					
Total R ²	81.98	93.33	85.85	97.77	99.77
Time-Series R ²	9.57	51.30	46.97	20.26	85.24
Cross-Section R ²	8.77	51.43	6.85	86.51	98.69
Relative Pricing Error	48.70	27.81	97.29	0.65	0.39

5.3 IPCA 与常见机器学习算法对比

相较于传统因子定价模型, 机器学习模型为资产定价领域提供了新的视角. 为系统评估 IPCA 模型在基金业绩预测中是否优于经典的机器学习算法, 本文在表6中将三个因子的 IPCA 模型 ($K = 3$) 与弹性网络 (ENet)、偏最小二乘 (PLS)、主成分回归 (PCR)、随机森林 (RF) 及梯度提升树 (GBRT) 进行对比分析. 实证结果表明, 无论是在个体基金层面 (面板 A) 还是投资组合管理层面 (面板 B), 三因子 IPCA 模型均展现出显著优势, 这种优越性可以从更大的拟合优度以及更小的相对定价误差得以体现. 在基金个体层面 (面板 A), IPCA 模型的总体拟合优度高达 79.23%, 远超其他五种机器学习模型 (均值仅为 1.55%), 同时将相对定价误差从平均 62.91% 的水平缩减至 29.03%; 而在投资组合层面 (面板 B), 这一优势进一步扩大.

5.4 IPCA 定价能力来源

如何解释 IPCA 模型所识别的隐性因子的定价能力, 对于理解和应用 IPCA 模型来说至关重要, 因此, 本节将从特征与宏观因素两方面探究隐性因子定价能力的来源.

表 6 IPCA 与其他机器学习模型表现对比

	ENet	PLS	PCR	RF	GBRT	IPCA(K=3)
面板 A: 单个基金						
Total R ²	1.53	1.46	1.46	1.53	1.75	79.23
Time-Series R ²	1.32	1.25	1.22	1.31	1.54	77.83
Cross-Section R ²	0.17	-0.01	-0.06	0.22	-0.96	61.91
Relative Pricing Error	63.44	62.18	63.36	62.84	62.75	29.03
面板 B: 管理投资组合						
Total R ²	0.34	1.70	1.67	0.75	0.15	99.76
Time-Series R ²	-1.07	-0.09	-0.57	-3.55	-0.23	86.84
Cross-Section R ²	0.73	-5.50	-5.73	-5.61	0.27	98.16
Relative Pricing Error	86.11	25.77	25.82	30.04	85.41	0.13

5.4.1 基金与持仓股票特征

整体因子。图2说明了各个特征对于 IPCA 模型解释能力的重要性。参考 Gu 等^[42], 本文通过逐一剔除各特征、重新计算模型拟合优度 (基于剩余 27 个特征) 的方式, 判断各特征对 IPCA 模型定价能力的贡献程度。换言之, 本文将剔除某特征后模型整体拟合优度下降的基点作为特征重要程度的代理指标, 图2依次对这一指标进行了排列。其中, 纵坐标代表该特征的重要程度, 即拟合优度下降的基点; 在横坐标上, 本文按照 28 个特征变量的重要性从左到右进行排序; 实心部分 (空心部分) 代表该特征为基金持仓股票的特征 (基金特征)。本文发现, 基金持仓股票的市值与行业调整后的市值为隐性因子最重要的特征; 从整体上来看, 对于隐性因子而言, 持仓股票特征比基金特征更为重要。接下来, 本文将对各因子进行逐一解释。




图 2 各特征重要性

各个因子。由前可知, 本文在 IPCA 模型的框架中以 28 个基金层面的特征作为工具变量、训练并提取了隐性定价因子, 但不同特征对各隐性定价因子的贡献程度不同, 而不同特征贡献程度的差异将决定如何解释隐性定价因子。以 Kelly 等^[8]在美国债券市场的研究为例, 其通过 IPCA 模型识别出的第一个隐性因子在债券利差 (spread) 这一特征上具有明显高于其他特征的贡献程度, 因而, 他们认为该隐性因子本质上为利差因子。类似地, 本文通过各隐性因子在各特征上的暴露程度大小, 解释不同隐性因子定价能力的经济意义⁸。

⁸技术上而言, 由式(3)和式(4)可知, IPCA 模型中各潜在定价因子 f_{t+1} 对基金未来收益的解释能力主要由风险载荷

图3展示了 28 个特征分别对 5 个潜在定价因子影响的重要程度 (Γ_β). 其中, 横坐标为 28 个特征的变量名, 实心部分为 14 个基金特征, 空心部分为 14 个基金持仓的股票特征, 纵坐标代表各特征变量的参数矩阵 Γ_β 的数值. 对于因子 1 来说, 基金持仓股票的总市值 (ME) 的贡献度约为-0.35, 其次是持仓股票的行业调整市值 (me_deIndus), 其贡献程度达到了 0.25, 而其他特征对因子 1 的贡献程度在数值意义上均小于 0.20 (24 个特征小于 0.10), 因此, 本文认为因子 1 的定价能力主要来源于持仓股票的市值特征. 这一结论对因子 2 同样适用, 有所不同的是, 因子 2 还表现出基金对持仓股票市值特征的对冲. 具体而言, 就绝对值水平来说, 持仓股票的市值 (ME) 与行业调整市值 (me_deIndus) 仍然是因子 2 最重要的两个组成部分 (这点与因子 1 类似), 但这两个特征对因子 2 的贡献在方向上均与对因子 1 的贡献相反. 这表明, 因子 2 在很大程度上为因子 1 的对冲因子, 即基金在持仓股票市值风险上的对冲. 因此, 本文认为, 因子 1 和因子 2 在很大程度上代表了股票的市值因子, 这一发现也同以往研究所认为的股票市值因子是基金市场的主要定价因子的结论相一致^[13].




图 3 IPCA 因子的特征载荷

对于因子 3 和因子 4, 不同基金持仓特征对于因子的贡献程度较为平均, 但基金持仓股票特征的贡献程度在整体上仍要高于基金特征, 这说明因子 3 与因子 4 的定价能力主要来源于股票市场的部分特征. 而在 IPCA 的框架下, 本文将资产特征向量 $z'_{i,t}$ 作为工具变量来估计时变风险载荷矩阵, 进而, 参数矩阵 Γ_β 则代表了时变风险载荷在各资产特征上的暴露. 因此, 可以将各特征变量的参数矩阵大小作为其对因子定价能力重要性的代理指标, 进一步判断各潜在定价因子定价能力的主要来源.

征,即,因子3和因子4在一定程度上可以代表股票的市场因子.对于因子5,各基金特征和持仓股票特征的重要性表现相似且较为平均,这表明因子5一定程度上可以代表整个市场环境的基本面因子.基于此,若因子3、4、5不止代表单个特征所形成的风格因子,而是代表市场环境对基金业绩的影响,那么本文预期宏观因素波动将对这三个因子带来更大的影响.

5.4.2 宏观因素

隐性因子对资产的定价能力可能由整个市场环境的基本面因素驱动,而不是单纯由某个特征所决定^[68].因此,本文进一步从宏观因素方面探究了各个隐性因子的驱动因素.具体而言,本文参照周炜等^[61]选取了中国市场中常见的28个宏观变量作为自变量,以IPCA模型得到的隐性因子作为因变量,设定以下单变量回归模型,以独立探究各宏观因素对IPCA因子的影响程度:

$$Factor_t^f = \alpha_t^{f,m} + \beta_t^{f,m} Macro_t^m + \epsilon_t^{f,m},$$

其中, $Factor_t^f$ 代表IPCA模型的五个隐性因子 ($f=1,2,3,4,5$), $Macro_t^m$ 为宏观变量 m , 回归系数 $\beta_t^{f,m}$ 则代表宏观变量 m 对因子 f 影响的重要程度,为保证各回归系数之间具有可比性,本文对各宏观变量进行了标准化处理.进一步地,为避免过拟合的问题,本文利用PLS回归中的拟合优度来代表宏观因素整体上对各隐性因子的解释程度.各单变量回归系数及PLS回归的拟合优度分别汇报在表7的面板A和面板B中.

表7展示了宏观因素对5个IPCA因子的影响程度.面板A展示了5个IPCA因子对各宏观因素的单变量回归系数⁹.相较于因子1和因子2,因子3、4、5更多地被股债市场流动性相关的指标所影响,这与上一节的结论一致,进一步说明后三个因子更多地代表了市场整体交易环境的基本面因素.与之对应的是,面板B中PLS回归的拟合优度表明,宏观变量整体对因子3波动的解释力度达到了16.06%,而对于因子4和因子5而言,这一解释程度分别为11.15%和13.28%.但对于因子1和因子2而言,宏观因素的整体解释力度明显小于其他因子.因此,这进一步说明,因子1和2代表了基金单个特征因子,而因子3、4、5则代表了宏观因素对基金业绩的影响.

表7 IPCA模型表现来源:影响前五的宏观因素

因子1		因子2		因子3		因子4		因子5	
变量	估计	变量	估计	变量	估计	变量	估计	变量	估计
面板 A: 宏观因素分别的重要程度									
R _{Yield10Y}	-0.18 (-2.15)	MacroLev	0.15 (1.82)	IlliBond	-0.13 (-1.84)	UncIndProd	-0.16 (-1.51)	IlliStock3	-0.17 (-1.85)
CPI1Y	-0.18 (-2.77)	CPI1Y	-0.15 (-2.50)	UncCorpProfit	-0.12 (-1.62)	Vol _{Rf}	0.11 (1.93)	IlliStock2	0.17 (2.23)
Cor _{Infl-OutputGap}	-0.14 (-2.15)	IlliBond	-0.12 (-1.61)	Vol _{SEEC5Y}	0.11 (1.60)	UncMacro	-0.10 (-1.52)	IlliStock1	0.16 (2.01)
UncOutput	0.14 (2.20)	IlliStock2	0.12 (1.80)	UncOutput	0.10 (1.23)	IlliBond	0.09 (1.58)	Vol _{SEEC1Y}	0.14 (1.91)
G _{IndProd}	-0.13 (-1.73)	Vol _{Rf}	-0.10 (-1.08)	Vol _{Rf}	-0.09 (-1.17)	IlliStock1	0.08 (1.29)	UncIndProd	0.14 (2.67)
面板 B: 整体宏观因素对隐性因子的解释力度									
PLS R ²	0.0756	PLS R ²	0.1055	PLS R ²	0.1606	PLS R ²	0.1115	PLS R ²	0.1328
Obs	171	Obs	171	Obs	171	Obs	171	Obs	171

5.5 异质性分析

不同类型的基金或不同的市场环境下,因子表现也可能存在一定差异.本文基于三种常见的基金特征进行异质性分析,以探究IPCA模型在识别不同类型或不同市场环境的基金未来收益时的表现.表8展示了在不同分组下,IPCA模型对基金未来收益的整体拟合优度.其中,面板A基于基金资产净

⁹限于篇幅,此处仅展示对各个隐性因子最重要的五个宏观变量,感兴趣的读者可联系作者获取完整的表格.

值, 以两亿、十亿、二十亿元作为分界线, 将基金样本分成从小到大 (Small to Large) 四组, 结果显示, IPCA 模型在识别资产净值更大的基金时表现更好; 面板 B 基于基金过往业绩的四分位数将基金样本分成从低到高 (Bad to Good) 四组, 总的来说, 整体拟合优度的组间差异不明显, IPCA 模型在识别过往业绩更好的基金未来收益时表现出微小的优势; 面板 C 基于 Baker 和 Wurgler^[69] 提出的投资者情绪指数的四分位数将样本期分成从低到高 (Low to High) 四组, 能够明显看出, 在投资者情绪更低的时期, IPCA 模型在识别基金未来收益时有着更加优异的表现. 综上所述, IPCA 模型在识别资产净值更大、过去业绩更突出 (过往业绩最好和最坏) 以及投资者情绪指数更低时期的基金未来收益时表现更加优异.

表 8 IPCA 模型的异质性表现

	因子个数(K)				
	1	2	3	4	5
面板 A: 基金总资产净值					
1 (Small)	72.35	75.83	77.43	78.38	79.02
2	74.11	78.31	80.16	81.01	81.48
3	75.98	80.06	82.41	83.45	84.09
4 (Large)	79.63	83.12	85.18	85.93	86.51
面板 B: 过往业绩					
1 (Bad)	78.43	80.56	82.27	83.05	83.55
2	73.66	77.35	79.67	80.39	80.89
3	71.66	76.15	78.69	79.80	80.33
4 (Good)	78.60	82.75	84.14	84.88	85.35
面板 C: 投资者情绪					
1 (Low)	80.61	83.14	84.32	84.89	85.25
2	75.83	79.48	81.29	82.18	82.58
3	80.98	83.79	85.26	85.82	86.13
4 (High)	65.06	72.33	74.42	75.60	76.19

5.6 稳健性分析

考虑到月度数据无法捕捉影响基金市场的短期波动, 或其它交易频率较高的因素, 本文进一步构建日度频率下的基金特征和持仓股票特征, 以探究 IPCA 模型对基金定价能力在日频数据下的表现.

表9分别展示了无截距项和有截距项 IPCA 模型对基金业绩的样本内预测结果. 无截距项 (面板 A) 的拟合结果显示, 在提高数据样本频率之后, 单个基金层面 (面板 A1) 的拟合效果有了进一步的提升, 五个因子 IPCA 模型 ($K = 5$) 的整体拟合优度从月度数据的 81.85% 提升到了 84.04%, 相对定价误差则从 27.00% 下降至 13.91%; 基金组合层面 (面板 A2) 的相对定价误差则从 0.21% 扩大至 2.89%, 但整体拟合优度变化不大且仍保持在较高水平 (99.82% 和 99.75%). 有截距项 (面板 B) 的拟合结果也呈现出类似规律: 单个基金层面 (面板 B1) 的五个因子 IPCA 模型 ($K = 5$) 的整体拟合优度从 81.90% 提升至 84.05%, 相对定价误差从 26.23% 下降至 13.60%; 基金组合层面 (面板 B2) 的相对定价误差从 0.02% 扩大至 0.71%, 整体拟合优度也保持在高水平 (99.82% 和 99.75%). 同样的, 自举检验 (面板 C) 得到的各 p 值均大于 0.1, 说明 IPCA 模型的截距项在 10% 的置信水平下不显著区别于零, 即, 无论单个基金还是基金组合, 在 IPCA 所识别出的隐性因子模型中均不能获得统计意义上显著的超额回报. 为避免训练参数时出现前瞻误差 (look-ahead bias), 本文进一步检验了 IPCA 模型对日频数据在样本外的预测能力, 结果发现, 隐性因子模型的优异定价能力在样本外检验中依旧保持稳健.

表 9 IPCA 模型高频下的表现: 样本内

	因子个数(K)				
	1	2	3	4	5
面板 A: $\Gamma_{\alpha} = 0$					
面板 A1: 单个基金					
Total R ²	77.16	80.33	82.29	83.36	84.04
Time-Series R ²	76.34	79.36	81.50	82.50	83.13
Cross-Section R ²	58.70	62.23	65.44	67.19	68.25
Relative Pricing Error	19.25	17.79	16.46	14.73	13.91
面板 A2: 管理投资组合					
Total R ²	97.76	98.85	99.48	99.66	99.75
Time-Series R ²	15.28	51.35	74.79	81.60	84.85
Cross-Section R ²	85.76	91.52	95.48	96.95	97.74
Relative Pricing Error	28.56	16.03	10.07	9.22	2.89
面板 B: $\Gamma_{\alpha} \neq 0$					
面板 B1: 单个基金					
Total R ²	77.19	80.35	82.30	83.37	84.05
Time-Series R ²	76.36	79.38	81.51	82.51	83.13
Cross-Section R ²	56.61	60.82	64.74	66.55	67.86
Relative Pricing Error	17.31	16.02	15.40	13.94	13.60
面板 B2: 管理投资组合					
Total R ²	97.76	98.85	99.48	99.66	99.75
Time-Series R ²	15.55	51.52	74.85	81.65	84.87
Cross-Section R ²	80.45	88.07	94.38	95.96	97.33
Relative Pricing Error	9.23	5.30	2.41	0.83	0.71
面板 C: 自举检验(Bootstrap Test, H0: $\Gamma_{\alpha} = 0$)					
p 值	0.78	0.85	0.49	0.33	0.26

6 结论与政策建议

如何有效、准确识别公募基金业绩的影响因素,对于普通投资者进行资产配置及市场健康、高效运行具有重要意义。本文利用中国市场公募基金数据和股票数据,选取了 28 个特征作为工具变量训练 IPCA 模型得到五个隐性因子,并探究了五个隐性因子在识别基金业绩方面的表现。本文主要结论如下:首先,五个隐性因子在样本内能够很好地解释基金业绩,在样本外也表现出优异的预测能力,且这些隐性因子相比于传统的显性因子模型和其它机器学习模型具有更好的表现。其次,本文提出的基于 IPCA 模型的投资策略是对现有基金资产的线性组合,对于普通投资者来说具有可操作性且能够获得正的预期收益、夏普比率和异常回报。进一步研究表明,这些隐性因子的定价能力主要来源于股票市值因子和股票市场因子;除此之外,包括通货膨胀率、国债利率、宏观杠杆率、股债市场流动性及工业生产不确定性等一系列宏观因素也影响着隐性因子模型的定价能力。最后,异质性分析表明,隐性因子模型在识别资产净值更大、过去业绩更突出(过往业绩最好和最坏)以及投资者情绪指数更低时期的基金未来收益时表现更加优异。

本文对推动基金行业稳健发展、强化金融市场服务实体经济功能具有积极启示。首先,基于隐性因子定价模型相较于传统方法的解释力优势,市场参与者可进一步探究隐性因子模型在基金业绩评估中的适配性应用,尤其重视隐性因子模型在高资产净值基金当中、业绩表现极端时期以及市场情绪低落时期的应用,构建科学性与包容性兼具的多元化基金评价体系。其次,鉴于宏观经济因素对隐性因子定价能力的显著影响,基金管理者可加强对于宏观政策与微观市场环境的动态分析,关注财政、货币等政策的传导效应及其对资产定价因子的潜在影响,提升风险应对的前瞻性。此外,在投资者保护层面,应持续

优化投资者教育机制, 引导个人投资者逐步转向以因子透明度、政策适配度为参照的理性决策模式, 同时结合因子模型的风险预警功能, 针对性开展对个人投资者的市场周期适应性教育, 推动个人投资者行为向专业化、理性化方向转型。最后, 进一步完善上市公司信息披露和交易监管机制, 营造规范有序的市场生态, 畅通资本与实体经济的良性互动渠道, 切实发挥金融资源配置对经济高质量发展的支撑作用。

参考文献

- [1] Grinblatt M, Titman S. The persistence of mutual fund performance[J]. *The Journal of Finance*, 1992, 47(5): 1977–1984.
- [2] Jones C S, Mo H. Out-of-sample performance of mutual fund predictors[J]. *The Review of Financial Studies*, 2021, 34(1): 149–193.
- [3] Kaniel R, LI J J, Shi D, et al. Benefits of partial vs full mandatory disclosure[R]. SSRN Working Paper No. 4014878, 2023.
- [4] Li B, Rossi A G. Selecting mutual funds from the stocks they hold: A machine learning approach[R]. SSRN Working Paper No. 3737667, 2020.
- [5] DeMiguel V, Gil-Bazo J, Nogales F J, et al. Machine learning and fund characteristics help to select mutual funds with positive alpha[J]. *Journal of Financial Economics*, 2023, 150(3): 103737.
- [6] Kelly B T, Pruitt S, Su Y. Characteristics are covariances: A unified model of risk and return[J]. *Journal of Financial Economics*, 2019, 134(3): 501–524.
- [7] Cochrane J H. Presidential address: Discount rates[J]. *The Journal of Finance*, 2011, 66(4): 1047–1108.
- [8] Kelly B, Palhares D, Pruitt S. Modeling corporate bond returns[J]. *The Journal of Finance*, 2023, 78(4): 1967–2008.
- [9] Büchner M, Kelly B. A factor model for option returns[J]. *Journal of Financial Economics*, 2022, 143(3): 1140–1161.
- [10] Ma T, Leong W J, Jiang F. A latent factor model for the Chinese stock market[J]. *International Review of Financial Analysis*, 2023, 87: 102555.
- [11] 李江远, 周炜, 杨金强. 因子模型能定价期权收益吗?[R]. 工作论文, 2024.
- [12] Fama E F, French K R. The cross-section of expected stock returns[J]. *The Journal of Finance*, 1992, 47(2): 427–465.
- [13] Carhart M M. On persistence in mutual fund performance[J]. *The Journal of Finance*, 1997, 52(1): 57–82.
- [14] Liu J, Stambaugh R F, Yuan Y. Size and value in China[J]. *Journal of Financial Economics*, 2019, 134(1): 48–69.
- [15] Chen J, Hong H, Huang M, et al. Does fund size erode mutual fund performance? The role of liquidity and organization[J]. *American Economic Review*, 2004, 94(5): 1276–1302.
- [16] Pollet J M, Wilson M. How does size affect mutual fund behavior?[J]. *The Journal of Finance*, 2008, 63(6): 2941–2969.
- [17] Pástor L, Stambaugh R F, Taylor L A. Do funds make more when they trade more?[J]. *The Journal of Finance*, 2017, 72(4): 1483–1528.
- [18] Lou D. A flow-based explanation for return predictability[J]. *The Review of Financial Studies*, 2012, 25(12): 3457–3489.
- [19] Hendricks D, Patel J, Zeckhauser R. Hot hands in mutual funds: Short-run persistence of relative performance, 1974–1988[J]. *The Journal of Finance*, 1993, 48(1): 93–130.
- [20] 庄云志, 唐旭. 基金业绩持续性的实证研究 [J]. *金融研究*, 2004, (05): 20–27.
Zhuang Y Z, Tang X. An empirical study on the persistence of fund performance[J]. *Journal of Financial Research*, 2004, (05): 20–27.
- [21] Ben-David I, Li J, Rossi A, et al. What do mutual fund investors really care about?[J]. *The Review of Financial Studies*, 2022, 35(4): 1723–1774.
- [22] Huang J, Sialm C, Zhang H. Risk shifting and mutual fund performance[J]. *The Review of Financial Studies*, 2011, 24(8): 2575–2616.
- [23] 刘莎莎, 刘玉珍, 唐涯. 信息优势、风险调整与基金业绩 [J]. *管理世界*, 2013, (08): 67–76.

- Liu S S, Liu Y Z, Tang Y. Information advantage, risk shifting and fund performance [J]. *Management World*, 2013, (08): 67–76.
- [24] 杨小欣, 李仲飞. 基金的交易券商网络与投资业绩 [J]. *系统工程理论与实践*, 2023, 43(10): 2807–2826.
Yang X X, Li Z F. Brokerage networks and mutual fund performance[J]. *Systems Engineering — Theory & Practice*, 2023, 43(10): 2807–2826.
- [25] 李斌, 雷印如. 中国公募基金挖掘了股票市场异象吗?[J]. *金融研究*, 2022, (09): 188–206.
Li B, Lei Y R. Do mutual funds exploit stock market anomalies in China?[J]. *Journal of Financial Research*, 2022, (09): 188–206.
- [26] 林斌, 何为, 余剑峰. 公募基金管理是否有效?——多因素的基金能力评价 [J]. *系统工程理论与实践*, 2022, 42(04): 906–922.
Lin S, He W, Yu J F. Is the management of mutual fund valid? — Ability evaluation based on multiple characteristics[J]. *Systems Engineering — Theory & Practice*, 2022, 42(4): 906–922.
- [27] Kacperczyk M, Sialm C, Zheng L. On the industry concentration of actively managed equity mutual funds[J]. *The Journal of Finance*, 2005, 60(4): 1983–2011.
- [28] Bai J J, Tang Y, Wan C, et al. Fund manager skill in an era of globalization: Offshore concentration and fund performance[J]. *Journal of Financial Economics*, 2022, 145(2): 18–40.
- [29] Cremers K J M, Petajisto A. How active is your fund manager? A new measure that predicts performance[J]. *The Review of Financial Studies*, 2009, 22(9): 3329–3365.
- [30] 罗荣华, 兰伟, 杨云红. 基金的主动性管理提升了业绩吗?[J]. *金融研究*, 2011, (10): 127–139.
Luo R H, Lan W, Yang Y H. Does active management improve mutual fund's performance?[J]. *Journal of Financial Research*, 2011, (10): 127–139.
- [31] Kacperczyk M, Sialm C, Zheng L. Unobserved actions of mutual funds[J]. *The Review of Financial Studies*, 2008, 21(6): 2379–2416.
- [32] 申宇, 赵静梅, 何欣. 基金未公开的信息: 隐形交易与投资业绩 [J]. *管理世界*, 2013, (08): 53–66.
Shen Y, Zhao J M, He X. Unopened trading: Mutual fund unobserved trading and smart money effect[J]. *Management World*, 2013, (08), 55–66.
- [33] 罗荣华, 田正磊, 方红艳. “和而不群”还是“卓尔不群”?——基于基金网络信息使用的视角 [J]. *金融研究*, 2020, (08): 188–206.
Luo R H, Tian Z L, Fang H Y. Fund managers' skill and use of shared information from the social network[J]. *Journal of Financial Research*, 2020, (08): 188–206.
- [34] 罗荣华, 田正磊. 基金网络、竞争阻隔与股票信息环境 [J]. *中国工业经济*, 2020, (03): 137–154.
Luo R H, Tian Z L. Mutual fund network, competition barrier and stock information environment[J]. *China Industrial Economics*, 2020, (03): 137–154.
- [35] Agarwal V, Jiang L, Wen Q. Why do mutual funds hold lottery stocks?[J]. *Journal of Financial and Quantitative Analysis*, 2022, 57(3): 825–856.
- [36] Fang L H, Peress J, Zheng L. Does media coverage of stocks affect mutual funds' trading and performance?[J]. *The Review of Financial Studies*, 2014, 27(12): 3441–3466.
- [37] Chevalier J, Ellison G. Are some mutual fund managers better than others? Cross-sectional patterns in behavior and performance[J]. *The Journal of Finance*, 1999, 54(3): 875–899.
- [38] Cohen L, Frazzini A, Malloy C. The small world of investing: Board connections and mutual fund returns[J]. *Journal of Political Economy*, 2008, 116(5): 951–979.
- [39] 申宇, 赵静梅, 何欣. 校友关系网络、基金投资业绩与“小圈子”效应 [J]. *经济学 (季刊)*, 2016, 15(01): 403–428.
Shen Y, Zhao J M, He X. Alumni networks, funds' performance and “small world” effect[J]. *China Economic Quarterly*, 2015, 15(1): 403–428.
- [40] Bai J J, Ma L, Mullally K A, et al. What a difference a (birth) month makes: The relative age effect and fund manager performance[J]. *Journal of Financial Economics*, 2019, 132(1): 200–221.
- [41] Bai C, Tian S. What beauty brings? Managers' attractiveness and fund performance[R]. SSRN Working Paper No. 4322134, 2023.
- [42] Gu S, Kelly B, Xiu D. Empirical asset pricing via machine learning[J]. *The Review of Financial Studies*, 2020, 33(5): 2223–2273.

- [43] Neely C J, Rapach D E, Tu J, et al. Forecasting the equity risk premium: The role of technical indicators[J]. *Management Science*, 2014, 60(7): 1772–1791.
- [44] Light N, Maslov D, Rytchkov O. Aggregation of information about the cross section of stock returns: A latent variable approach[J]. *The Review of Financial Studies*, 2017, 30(4): 1339–1381.
- [45] Kozak S, Nagel S, Santosh S. Interpreting factor models[J]. *The Journal of Finance*, 2018, 73(3): 1183–1223.
- [46] 姜富伟, 薛浩, 周明. 大数据提升了多因子模型定价能力吗?——基于机器学习方法对我国 A 股市场的探究 [J]. *系统工程理论与实践*, 2022, 42(08): 2037–2048.
- Jiang F W, Xue H, Zhou M. Does big data improve multi-factor asset pricing models? Exploration of China's A-share market with machine learning[J]. *Systems Engineering — Theory & Practice*, 2022, 42(8): 2037–2048.
- [47] 李斌, 邵新月, 李玥阳. 机器学习驱动的基本面量化投资研究 [J]. *中国工业经济*, 2019, (08): 61–79.
- Li B, Shao X Y, Li Y Y. Research on machine learning driven quantamental investing[J]. *China Industrial Economics*, 2019, (08): 61–79.
- [48] 毛杰, 陈宓舟, 许磊, 等. 基于双重选择 LASSO 模型的我国股市定价因子边际有效性研究 [J]. *系统工程理论与实践*, 2024, 44(09): 2993–3005.
- Mao J, Chen M Z, Xu L, et al. Research on the marginal effectiveness of Chinese stock markets' pricing factors: Application of double-selection LASSO model[J]. *Systems Engineering — Theory & Practice*, 2024, 44(9): 2993–3005.
- [49] Leippold M, Wang Q, Zhou W. Machine learning in the Chinese stock market[J]. *Journal of Financial Economics*, 2022, 145(2): 64–82.
- [50] 马甜, 姜富伟, 唐国豪. 深度学习与中国股票市场因子投资——基于生成式对抗网络方法 [J]. *经济学 (季刊)*, 2022, 22(03): 819–842.
- Ma T, Jiang F W, Tang G H. Deep learning and factor investing in Chinese stock market — Based on generative adversarial networks[J]. *China Economic Quarterly*, 2022, 22(3): 819–842.
- [51] 倪宣明, 郑田田, 孙会霞, 等. 统计因子、经济因子, 殊途同归?[J]. *系统工程理论与实践*, 2023, 43(12): 3385–3406.
- Ni X M, Zheng T T, Sun H X, et al. Can statistical factors and economic factors reach the same goal in different ways?[J]. *Systems Engineering — Theory & Practice*, 2023, 43(12): 3385–3406.
- [52] 李斌, 屠雪永. 基于机器学习和资产特征的投资组合选择研究 [J]. *系统工程理论与实践*, 2024, 44(01): 338–355.
- Li B, Tu X Y. Research on portfolio selection based on machine learning and asset characteristics[J]. *Systems Engineering — Theory & Practice*, 2024, 44(1): 338–355.
- [53] Kaniel R, Lin Z, Pelger M, et al. Machine-learning the skill of mutual fund managers[J]. *Journal of Financial Economics*, 2023, 150(1): 94–138.
- [54] 林斌, 何为, 余剑峰. 基于相关性调整的公募基金管理能力度量 [J]. *管理科学学报*, 2022, 25(11): 109–126.
- Lin S, He W, Yu J F. A correlation-adjusted measure for the management ability of mutual funds[J]. *Journal of Management Sciences in China*, 2022, 25(11): 109–126.
- [55] 林斌, 何为, 余剑峰, 等. 公募基金改善了市场定价效率吗?——持股基金质量与股票收益 [J]. *金融研究*, 2023, (04): 149–167.
- Lin S, He W, Yu J F, et al. Do mutual funds improve price efficiency? Mutual fund holding quality and stock returns[J]. *Journal of Financial Research*, 2023, (04): 149–167.
- [56] Evans R B. Mutual fund incubation[J]. *The Journal of Finance*, 2010, 65(4): 1581–1611.
- [57] Fama E F, French K R. Choosing factors[J]. *Journal of Financial Economics*, 2018, 128(2): 234–252.
- [58] Du Q, Wang Y, Wei K C J. Does cash-based operating profitability explain the accruals anomaly in China?[J]. *Pacific-Basin Finance Journal*, 2020, 61: 101336.
- [59] Chen S, Liu X, Li T. Does the investment-profitability correlation affect the factor premiums? Evidence from China[J]. *Pacific-Basin Finance Journal*, 2023, 79: 102012.
- [60] Li Z, Liu L X, Liu X, et al. Replicating and digesting anomalies in the Chinese A-share market[J]. *Management Science*, 2024, 70(8): 5066–5090.
- [61] 周炜, 李江远, 杨金强. 谁驱动了股票和债券市场协同运动?——基于机器学习的视角 [R]. 工作论文, 2024.
- [62] Fama E F, French K R. Luck versus skill in the cross-section of mutual fund returns[J]. *The Journal of Finance*, 2010, 65(5): 1915–1947.
- [63] Harvey C R, Liu Y. Luck versus skill in the cross section of mutual fund returns: Reexamining the evidence[J]. *The Journal of Finance*, 2022, 77(3): 1921–1966.

- [64] Ross S A. The arbitrage theory of capital asset pricing[J]. *Journal of Economic Theory*, 1976, 13(3): 341–360.
- [65] Connor G, Korajczyk R A. Risk and return in an equilibrium APT: Application of a new test methodology[J]. *Journal of Financial Economics*, 1988, 21(2): 255–289.
- [66] Sharpe W F. Capital asset prices: A theory of market equilibrium under conditions of risk[J]. *The Journal of Finance*, 1964, 19(3): 425–442.
- [67] Berk J B, Van Binsbergen J H. Measuring skill in the mutual fund industry[J]. *Journal of Financial Economics*, 2015, 118(1): 1–20.
- [68] Chen Z, Roussanov N L, Wang X, et al. Common risk factors in the returns on stocks, bonds (and options), redux[R]. SSRN Working Paper No. 4703281, 2024.
- [69] Baker M, Wurgler J. Investor sentiment and the cross-section of stock returns[J]. *The Journal of Finance*, 2006, 61(4): 1645–1680.
- [70] Hunter D, Kandel E, Kandel S, et al. Mutual fund performance evaluation with active peer benchmarks[J]. *Journal of Financial Economics*, 2014, 112(1): 1–29.
- [71] Jegadeesh N, Titman S. Returns to buying winners and selling losers: Implications for stock market efficiency[J]. *The Journal of Finance*, 1993, 48(1): 65–91.
- [72] Ang A, Hodrick R J, Xing Y, et al. The cross-section of volatility and expected returns[J]. *The Journal of Finance*, 2006, 61(1): 259–299.
- [73] Brennan M J, Chordia T, Subrahmanyam A. Alternative factor specifications, security characteristics, and the cross-section of expected stock returns[J]. *Journal of Financial Economics*, 1998, 49(3): 345–373.
- [74] Cooper M J, Gulen H, Schill M J. Asset growth and the cross-section of stock returns[J]. *The Journal of Finance*, 2008, 63(4): 1609–1651.
- [75] Chen S, Liu X, Xue S. The positive investment premium in China[R]. SSRN Working Paper No. 4547695, 2023.
- [76] Ball R, Gerakos J, Linnainmaa J T, et al. Deflating profitability[J]. *Journal of Financial Economics*, 2015, 117(2): 225–248.
- [77] Sloan R G. Do stock prices fully reflect information in accruals and cash flows about future earnings?[J]. *Accounting review*, 1996: 289–315.
- [78] Hou K, Xue C, Zhang L. Digesting anomalies: An investment approach[J]. *The Review of Financial Studies*, 2015, 28(3): 650–705.
- [79] Asness C S, Porter R B, Stevens R L. Predicting stock returns using industry-relative firm characteristics[R]. SSRN Working Paper No. 213872, 2000.
- [80] Huang Y, Luk P. Measuring economic policy uncertainty in China[J]. *China Economic Review*, 2020, 59: 101367.

附录

A 变量定义

A.1 基金特征

参考 DeMiguel 等^[5], 本文选取了常见的预测未来业绩的基金自身特征.

ReaAlpha: 已实现异常回报. 用基金的月度超额收益率对 $FF6$ 因子进行 36 个月滚动窗口回归, 将回归得到的常数项作为基金的已实现异常回报.

t_mktrf: 市场风险溢价因子 t 值. 参考 Hunter 等^[70] 和 DeMiguel 等^[5], 用基金的月度超额收益率对 $FF6$ 因子进行 36 个月滚动窗口回归, 得到市场风险溢价因子 (mktrf) 系数的 t 值.

t_smb: 市值因子 t 值. 参考 Hunter 等^[70] 和 DeMiguel 等^[5], 用基金的月度超额收益率对 $FF6$ 因子进行 36 个月滚动窗口回归, 得到市值因子 (smb) 系数的 t 值.

t_hml: 账面市值比因子 t 值. 参考 Hunter 等^[70] 和 DeMiguel 等^[5], 用基金的月度超额收益率对 $FF6$ 因子进行 36 个月滚动窗口回归, 得到账面市值比因子 (hml) 系数的 t 值.

t_rmw: 盈利能力因子 t 值. 参考 Hunter 等^[70] 和 DeMiguel 等^[5], 用基金的月度超额收益率对 $FF6$ 因子进行 36 个月滚动窗口回归, 得到盈利能力因子 (rmw) 系数的 t 值.

t_cma: 投资模式因子 t 值. 参考 Hunter 等^[70] 和 DeMiguel 等^[5], 用基金的月度超额收益率对 $FF6$ 因子进行 36 个月滚动窗口回归, 得到投资模式因子 (cma) 系数的 t 值.

t_umd: 动量因子 t 值. 参考 Hunter 等^[70] 和 DeMiguel 等^[5], 用基金的月度超额收益率对 $FF6$ 因子进行 36 个月滚动窗口回归, 得到动量因子 (umd) 系数的 t 值.

t_alpha: 已实现异常回报 t 值. 参考 Hunter 等^[70] 和 DeMiguel 等^[5], 用基金的月度超额收益率对 $FF6$ 因子进行 36 个月滚动窗口回归, 将回归得到的常数项的 t 值作为基金的已实现异常回报 t 值.

FundAge: 基金成立月数. 基金成立以来的月数.

TNA: 总资产净值. 基金在月末的总资产净值 (万元).

QuartFlow: 基金流量. 基金的季度资金流量, 计算方法如下:

$$QuartFlow_{i,t} = \frac{TNA_{i,t} - TNA_{i,t-1}(1 + r_{i,t})}{TNA_{i,t-1}},$$

其中 TNA 为基金的总资产净值, r 为基金的季度累计回报率.

FlowVol: 流量波动率. 基金过去 12 个季度的资金流量标准差.

ExpRatio: 基金费率. 基金在最近一个报告期披露的总费用占基金总规模的比例.

ValAdd: 附加价值. 参考 Berk 和 Van Binsbergen^[67] 和 DeMiguel 等^[5], 基金的附加价值计算方法如下:

$$ValAdd_{i,t} = \frac{(\alpha_{i,t} + ExpRatio_{i,t}/6)}{TNA_{i,t-1}},$$

其中, $\alpha_{i,t}$ 为基金 i 在 t 期的已实现异常回报率, $ExpRatio_{i,t}$ 为基金 i 在最近一个报告期披露的基金费率, TNA 为基金最近披露的总资产净值.

A.2 股票特征

本文利用基金半年度披露的持仓数据, 基于 Li 和 Rossi^[4] 中对基金业绩影响前十的股票特征 (全为市场交易特征) 和常见的基于会计报表的特征, 在基金层面上定义了基金持仓股票特征, 本节详细介绍了本文所使用股票特征的定义, 括号内为变量在 CSMAR 中对应的代码.

Momentum: 动量. 参考 Jegadeesh 和 Titman^[71], 用过去 f 月 ($f=6,12,36$) 的累计回报率作为股票的 f 月动量 $Momf$ 的估计 (不包含最近一个月).

Beta: 贝塔系数. 用股票的月度超额收益率对 $CAPM$ 模型进行 5 年期 (至少 36 个月) 滚动窗口回归, 回归得到的市场风险溢价因子的系数即为贝塔系数.

iVol_CAPM: 异质波动率. 参考 Ang 等^[72], 用股票的月度超额收益率对 *CAPM* 模型进行 5 年期 (至少 36 个月) 滚动窗口回归, 将回归得到的残差的标准差作为异质波动率.

avg_RVol: 平均交易量. 参考 Brennan 等^[73], 平均交易量为过去 12 个月月度人民币交易量 (*Mnvaltrd*) 的平均值.

avg_turn: 平均换手率. 首先计算股票的月度换手率, 即月个股交易金额 (*Mnvaltrd*) 与月个股流通市值的比值, 再对过去 12 个月的月度换手率取平均作为平均换手率.

ME: 总市值. 月末收盘价与发行总股数的乘积. 如果一家公司同时在不同的交易所上市, 将不同交易所的市值之和作为其总市值.

ag_q4: 总资产增长率. 参考 Cooper 等^[74] 以及 Chen 等^[75], 总资产增长率为总资产 (*A001000000*) 的同比增长率.

log_bm: 账面市值比对数. 参考 Fama 和 French^[12], 账面市值比为账面权益与上一年末总市值之比, 其中账面权益为所有者权益 (*A003000000*) 合计减去少数股东权益 (*A003200000*).

op_qa: 营业利润总资产比. 参考 Ball 等^[76] 和 Du 等^[58], 营业利润总资产比为: 最近一个季度披露的营业利润 (*B001300000*) 与研发费用 (*B001219000*) 之和, 再除以总资产 (*A001000000*).

Accrual_q: 应计利润. 参考 Sloan^[77] 和 Du 等^[58], 应计营业利润定义为:

$$Accruals = \frac{(CA - \Delta CASH) - (\Delta CL - \Delta STD - \Delta TP) - DP}{AT},$$

其中, *CA* 为流动资产合计 (*A001100000*); *CASH* 为货币资金 (*A001101000*); *CL* 为流动负债合计 (*A002100000*); *STD* 为短期借款 (*A002101000*) 和一年内到期的非流动负债 (*A002125000*); *TP* 为应交税费 (*A002113000*); *DP* 为固定资产折旧、油气资产折耗、生产性生物资产折旧 (*D000103000*)、无形资产摊销 (*D000104000*) 以及长期待摊费用摊销 (*D000105000*) 之和.

ROE: 净资产收益率. 参考 Hou 等^[78], 净资产收益率为最近一个季度披露的净利润 (*B002000000*) 除以上季度末账面权益, 其中账面权益为股东权益总额 (*A003000000*) 减去少数股东权益 (*A003200000*).

me_deIndus: 行业调整市值. 参考 Asness 等^[79] 和李斌等^[47], 用股票的流通市值减去其所在行业股票的平均流通市值作为其行业调整市值.

A.3 宏观变量

参考周炜等^[61], 本文定义了常见的宏观变量以解释隐性因子的定价能力来源.

CPI10Y: 十年通货膨胀率. *CPI* 指数的 10 年年化增长率.

CPI1Y: 一年通货膨胀率. *CPI* 指数的 1 年同比增长率.

G_{IndProd}: 工业增加值增长. 规模以上企业工业增加值 1 年同比增长率.

G_{CorpProfit}: 工业企业利润增长. 规模以上企业工业利润 1 年同比增长率.

R_{Interbank}: 同业拆借利率. 全国银行间同业拆借利率 (隔夜, 加权平均利率).

R_{Repo}: 质押式回购利率. 全国银行间质押式回购交易利率 (7 天, 加权平均利率).

R_{Yield10Y}: 国债收益率. 十年期国债收益率.

R_{TStruc}: 国债期限结构. 十年和一年期国债期限利差.

Vol_{SSEC5Y}: 五年股市波动率. 上证指数收益率 5 年年化波动率.

Vol_{SSEC1Y}: 一年股市波动率. 上证指数收益率 1 年年化波动率.

Vol_{Rf}: 无风险收益波动率. 三月期国债真实收益率 (减去通胀) 1 年年化波动率.

Vol_{CPI5Y}: 五年通胀波动率. 通货膨胀率 5 年年化波动率.

Vol_{CPI1Y}: 一年通胀波动率. 通货膨胀率 1 年年化波动率.

Unc_{Macro}: 经济政策不确定性. Huang 和 Luk^[80] 构建的经济政策不确定性指数.

Unc_{Output}: 产出不确定性. 使用当前 GDP 增长率对过去 4 个季度虚拟变量和增长率滞后项做

AR(4) 回归, 模型残差项的绝对值.

UncInfl: 通胀不确定性. 使用当前通胀率对过去 12 个月虚拟变量和通胀率滞后项做 AR(12) 回归, 模型残差项的绝对值.

UncIndProd: 工业增加值不确定性. 使用当前工业增加值增长率对过去 12 个月虚拟变量和增长率滞后项做 AR(12) 回归, 模型残差项的绝对值.

UncCorpProfit: 工业企业利润不确定性. 使用当前工业利润增长率对过去 12 个月虚拟变量和增长率滞后项做 AR(12) 回归, 模型残差项的绝对值.

IlliStock1: 股市非流动性 (Amihud). 个股月内 Amihud 指标, 等权重加权.

IlliStock2: 股市非流动性 (换手率). 个股月内日均交易股份数/流通股份数, 流通市值加权.

IlliStock3: 股市非流动性 (Zeros). 个股月内零收益天数/交易天数, 流通市值加权.

IlliBond: 债市非流动性. 国债现券月成交额/国债托管总市值.

OutputGap: 产出缺口. (实际产出-潜在产出)/潜在产出.

SENT: 投资者情绪. 基于六个单项情绪指标主成分构建的投资者情绪指数.

M2: 货币供给量. 货币和准货币 (M2)1 年同比增长率.

MacroLev: 宏观杠杆率. 实体部门宏观杠杆率 1 年增长的百分点.

CorInfl-OutputGap: 通胀-产出缺口相关性. 通胀率和产出缺口滚动 5 年的相关系数.

CorInfl-IndProd: 通胀-工业增加值相关性. 通胀率和工业增加值增长率滚动 5 年的相关系数.

B 股票特征与宏观变量描述性统计

表 B1 股票特征与宏观变量描述性统计

变量	观测数	平均值	标准差	分位数		
				p25	p50	p75
面板 A: 股票特征						
<i>Mom6</i>	146 676	0.01	0.04	-0.01	0.01	0.03
<i>Mom12</i>	146 653	0.02	0.03	0.00	0.02	0.04
<i>Mom36</i>	146 654	0.02	0.01	0.01	0.02	0.03
<i>Beta</i>	146 652	1.05	0.20	0.90	1.06	1.19
<i>iVol_CAPM</i>	146 652	0.12	0.02	0.11	0.12	0.14
<i>avg_RVol</i> ($\times 10^9$)	146 685	17.76	15.97	5.83	11.65	24.95
<i>Avg_turn</i> ($\times 10^3$)	146 685	0.35	0.15	0.24	0.32	0.42
<i>ME</i> ($\times 10^6$)	146 685	118.20	140.80	26.11	59.81	157.90
<i>ag_q4</i>	146 655	0.30	0.14	0.20	0.27	0.36
<i>log_bm</i>	146 618	5.67	0.52	5.33	5.69	6.01
<i>op_qa</i>	146 655	0.07	0.04	0.03	0.06	0.09
<i>Accrual_q</i> ($\times 10^3$)	146 590	-4.79	3.55	6.18	-3.76	-2.35
<i>ROE</i>	146 627	0.10	0.06	0.05	0.10	0.15
<i>me_deIndus</i> ($\times 10^6$)	146 685	99.02	132.70	14.00	43.04	134.60
面板 B: 宏观变量 (%)						
<i>CPI10Y</i>	171	2.50	0.43	2.11	2.54	2.89
<i>CPI1Y</i>	171	2.34	1.75	1.51	2.09	2.87
<i>GIndProd</i>	171	8.68	5.13	5.90	7.60	11.20
<i>GCorpProfit</i>	171	12.32	31.45	-4.40	7.13	19.62
<i>RInterbank</i>	171	2.27	0.72	1.87	2.24	2.69
<i>RRepo</i>	171	2.89	0.93	2.37	2.72	3.41
<i>RYield10Y</i>	171	3.42	0.45	3.08	3.39	3.65
<i>RTStruc</i>	171	0.80	0.50	0.51	0.66	0.88
<i>VolSSEC5Y</i>	171	25.20	4.82	23.09	24.02	30.43
<i>VolSSEC1Y</i>	171	22.61	9.38	17.15	19.39	26.04
<i>VolRf</i>	171	2.16	0.57	1.76	2.20	2.54
<i>VolCPI5Y</i>	171	5.85	3.07	3.27	5.36	9.32
<i>VolCPI1Y</i>	171	3.13	2.27	1.46	2.29	3.93
<i>UncMacro</i>	171	143.88	26.61	126.78	140.66	157.04
<i>UncOutput</i>	171	1.42	2.09	0.37	0.55	1.45
<i>UncInfl</i>	171	0.41	0.36	0.14	0.32	0.61
<i>UncIndProd</i>	171	2.86	4.34	0.61	1.22	3.24
<i>UncCorpProfit</i>	171	11.10	12.93	3.30	7.57	13.33
<i>IlliStock1</i>	171	6.38	5.81	3.15	4.69	6.87
<i>IlliStock2</i>	171	146.56	65.50	101.04	130.81	168.41
<i>IlliStock3</i>	171	3.58	1.53	2.48	3.56	4.73
<i>IlliBond</i>	171	2.98	1.95	1.44	2.45	3.84
<i>OutputGap</i>	171	1.12	1.88	0.38	1.80	2.36
<i>SENT</i>	171	36.63	88.12	-23.50	32.00	90.50
<i>M2</i>	171	13.37	5.10	9.40	12.70	14.90
<i>MacroLev</i>	171	8.45	8.79	1.33	7.90	14.78
<i>CorInfl-OutputGap</i>	171	24.96	42.40	-3.63	35.36	52.83
<i>CorInfl-IndProd</i>	171	3.94	38.21	-30.88	17.60	29.80