

基金业绩分析^{*}

——基于有向学习网络的研究

罗荣华 赵森杨 方红艳

内容提要: 本文使用 LASSO 算法构建了基于基金持股数据的基金间动态学习网络,将基金研究中传统的无向网络扩展为有向网络,并检验了正向学习与反向学习两种不同的学习模式(信息利用方式)对基金业绩的影响,进而探讨了其背后的经济含义。实证结果表明:当基金作为被学习者(信息被观测方)时,被正向学习会显著提高其业绩,被反向学习会显著降低其业绩;当基金作为主动学习者(信息观测方)时,无论是正向学习还是反向学习均不会对其业绩造成显著影响;对基金学习动机的分析表明,基金参与学习是为了提升相对自己上期的业绩、防止业绩倒退,且反向学习相对更加有效。本文分析了信息传递方向、信息利用方式对基金业绩的影响,为如何将统计学习方法应用于金融问题的分析提供了一个新的视角。

关键词: LASSO; 基金业绩; 学习网络

DOI: 10.19343/j.cnki.11-1302/c.2021.08.003

中图分类号: F222.3

文献标识码: A

文章编号: 1002-4565(2021)08-0030-15

Mutual Fund Performance Analysis: Based on Directional Learning Network

Luo Ronghua Zhao Senyang Fang Hongyan

Abstract: Based on mutual fund portfolio holdings data, we build dynamic learning networks of mutual funds using LASSO, which extends traditional unidirectional fund networks to directional networks. We then analyze the impact of different learning modes, specifically, concordant learning and opposite learning, on mutual fund performance, and explore the economic implications of these learning modes. The empirical evidence shows that: Firstly, funds that are learned by others in the concordant mode can result in a performance improvement, while performance deteriorates if they are learned by others in the opposite mode. Secondly, funds, as learners, acting either in the concordant or the opposite direction, do not experience significant changes in performance. Finally, the analysis of the learning motivation shows that funds participate in learning to improve the performance from the previous cycle and avoid performance deterioration that may occur otherwise, and opposite learning is more effective. Our paper contributes to the literature by exploring, for the first time, the impact of the direction of information transfer and the way information is used on fund performance, and presents new insight into how statistical learning methods can be applied in financial research.

Key words: LASSO; Mutual Fund Performance; Learning Network

^{*} 基金项目: 国家自然科学基金面上项目“信息扩散对资产定价与投资者行为的影响机制研究: 基于复杂网络结构的视角”(71873110)。

一、引言

金融市场是一个信息高度密集的市场,使用恰当的统计方法来理解市场中的信息传递方式是学界和业界共同关心的关键问题之一。在复杂多变的市场环境中,投资者往往难以凭借自身信息做出准确决策,经常会通过外部学习来获取更多信息,作为市场重要参与者的基金等机构投资者是学习和使用各类信息的典型代表。Lee 和 So(2015)指出美国机构投资者每月会进行外部学习,以获取有价值的信息。对基金经理来说,其学习对象不仅可以是分析师报告,还可以是市场上的同业人员。不同于卖方分析师,基金从业人员具有丰富的实际投资经验,还有相似的利益诉求,其信息在同行之间有更高的参考价值。但基金经理的学习行为不能被直接观察,需要采用合理的方式来刻画。如何恰当刻画基金经理间的学习模式进而理解其背后的行为动机正是本文关心的主要问题。

近些年来兴起的网络分析方法为刻画并理解基金间的信息传递提供了新的视角。大量研究论证了基金间的信息互动(Cohen 等,2008; Crawford 等,2017)会显著影响基金行为和业绩。而既有讨论均基于静态的背景或持仓信息,无法刻画出信息互动过程中信息传递方向及信息利用方式两个重要特征。在信息互动中,基于同一信息做出的相反决策(买入/卖出)以及信息利用的时间差异(信息被观测方/信息观测方)均会对基金业绩产生不同影响。为此,基于Bala 和 Goyal(2001)的个体选择理论,本文使用Tibshirani(1996)提出的LASSO方法,利用其在高维特征分析的良好性质(张兴祥等,2018),将其融入综合了基金持仓数据的回归模型中,构建了可以反映信息不同传递方向及利用方式的基金学习网络。

本文聚焦于基金经理对公开披露的资产组合信息的学习机制。具体来说,若上一期A基金的投资行为可以预测B基金的投资行为,则两基金间可能存在学习关系。其中,A基金为被学习者(信息被观测方),B基金为学习者(信息观测方),由此学习网络可以反映出信息传递方向的非对称性。特别地,若A基金的投资行为可以正向预测B基金的投资行为,即为B基金的正向学习;A基金的投资行为反向预测B基金的投资行为,则为B基金的反向学习。融入学习网络的基金业绩分析结果表明,基金主动学习其他基金和被其他基金学习,以及正向利用信息和反向利用信息对其业绩影响存在显著差异。当基金作为被学习者时,被其他基金正向学习会带来正的风险调整收益,被其他基金反向学习会带来负的风险调整收益。但是,当基金作为主动学习者时,正向学习与反向学习对其绝对业绩无显著影响。通过模拟基金不学习,仅依据自身特征维持既有资产组合,本文发现若基金不参与学习则其下一期的业绩相对学习将会下降。换言之,基金的主动学习虽然与业绩无显著关联,但主动学习至少能保证取得相对自己过去的业绩优势。

本文可能的边际贡献如下:①本文拓展了既有关于基金网络的研究,考虑了信息传递方向、信息利用方式的差异化影响,为基金网络相关研究提供了全新思路;②既有研究大多从基金的私有信息含量角度分析其业绩,却较少从外部学习角度检验基金的业绩差异,本文以此为视角对基金业绩进行了剖析;③本文基于LASSO算法构建基金的学习网络,利用投票机制增强统计学习方法的经济含义,这些探索为如何将统计学习方法应用于金融问题的分析提供了新的视角。

二、文献综述与研究假设

(一) 文献综述

1. 基金业绩来源。

目前学术界的主流观点认为基金的业绩决定于其主动管理水平,基金通过主动管理来获取

私有信息、进而进行有效的资产组合配置。对基金业绩的研究也就有赖于对基金主动管理水平的识别。相关研究大致可以分为两类,一类是采用一些统计方法来衡量基金投资对信息的依赖程度。Amihud 和 Geyonko(2013) 计算了基金净值收益率与指数收益率回归的可决系数 R^2 , 通过 $1 - R^2$ 度量基金投资对私有信息的依赖程度,基于此来验证基金业绩与主动管理水平间的关系。罗荣华等(2011) 认为简单的 R^2 中缺少基金投资组合的信息,因此他们复合了 R^2 与跟踪误差来综合衡量基金的私有信息含量,发现私有信息与超额收益间存在显著正相关关系,证实了我国基金通过主动管理可以提升其业绩。Kacperczyk 和 Seru(2007) 将分析师推荐级别作为公共信息的代理变量,计算了基金的股票持仓变动对往期分析师推荐级别变化回归后的 R^2 , 将其定义为公共信息依赖性(Reliance on Public Information, RPI),发现基金越依赖公共信息,其业绩越差。Choi 等(2017) 通过对基金资产组合集中度的检验发现,基金经理拥有越多信息其资产组合集中度越高,业绩也越好。

另一类文献更关注于基金个体特质。例如,Massa 和 Patgiri(2008) 研究了基金经理的薪酬激励机制对其管理水平的影响,他们将管理费与基金规模负相关的基金定义为低激励基金,正相关的则定义为高激励基金,发现高激励的基金经理会有更高的主动管理水平。Pastor 等(2017) 研究了基金换手率与基金主动管理水平的关系,发现由高换手率形成的高交易成本可以被基金的收益填补,高换手率的基金可以通过高的管理水平获得好的业绩。另有文献从基金规模、基金管理人特质如学历、性别、团队人数等(Chevalier 和 Ellison, 1999) 来分析具备什么特征的基金更具有主动管理水平。

2. 社交网络。

近年来,大量文献开始研究机构和个体投资者如何通过社交网络进行交流以及社交网络如何影响到他们的交易决策和投资业绩(Hong 等,2005; Cohen 等,2008)。这其中讨论较多的一类网络是关系网络。例如,Cohen 等(2008) 通过建立共同基金经理以及公司高管的教育网络发现,基金经理会更多地购买与自己具有相同教育背景高管的公司股票,且这种行为会带来超额收益,表明基金经理可以通过网络获得内幕消息。申宇等(2016) 论证了我国校友网络的存在性,认为具有校友关系的基金经理可能会相互交换私有信息以提升投资业绩。另外一种讨论较多的网络是地理位置网络。Hong 等(2005) 发现同一城市基金经理的投资决策比不同城市基金经理的投资决策更相似,表明基金经理会在一个以城市为基础的网络中交换信息,并相应地调整投资决策。进一步,Pool 等(2015) 研究了同一城市中不同社区居住地对基金经理投资决策的影响,发现同一社区的基金经理间持仓行为更为相似,由邻近经理买入的股票多头和邻近经理卖出的股票空头组成的交易策略所带来的风险调整回报率显著为正,表明网络间传递了有价值的信息。

随着对基金行为研究的不断深入,一种基于交易行为的网络构建方式引起了关注。Pareek(2012) 认为重仓持有同一只股票的基金经理可能存在某种社会联系,他们基于两基金重仓持有相同股票建立网络,发现基金网络中的交易行为相似,且这种相似性与基金的投资风格以及地理因素无关。采用与 Pareek 相同的网络构造方式,肖欣荣等(2012) 构建了我国市场的共同持股网络,通过检验基金网络结构对重仓股票动量或反转效应的影响来解释基金羊群行为。刘京军和苏楚林(2016) 用相同网络构造探究基金资金流量的网络溢出效应,研究发现网络在资金流与业绩的反馈关系中发挥重要作用。基金的持股网络带来资金流入,流入后的资金使得资产组合规模扩大并通过网络提升基金下期业绩,业绩的提升进一步吸引资金流入。陈新春等(2017)、田正磊等(2019) 与罗荣华和田正磊(2020) 均通过类似的网络构建来研究机构投资者之间的信息互动对股票风险

及信息环境的影响。

可以看出,上述文献考虑的都是无向信息交流网络。根据 Brown 等(1996)对共同基金锦标赛的研究,由于基金间存在业绩排名的压力,基金间的业绩竞争激烈,这种竞争会减少在网络中进行信息交换的可能性。更重要地,现有文献的基金信息网络构建方式没有考虑信息的传递方向及利用方式。因此,通过上述静态、无向网络来实证研究网络与基金业绩的关系存在可以改进的空间。

(二) 研究假设

关于学习的一个典型研究来自于 Conley 和 Udry(2010),他们发现农场主会将自己的生产要素投入向往期产出高的农场主看齐,这是因为往期生产效益高的农场主往往具有比较丰富的专业技能与经验,向这些优秀农场主学习更能够提高产出。对于基金而言,也可能存在类似的学习机制。市场上存在经验丰富、专业技能强的投资经理,他们往往具有较好的历史业绩,因此会吸引其他基金经理向其学习,本文将此学习过程定义为正向学习。不过,与农场主学习不同的是,基金不仅可以买入股票,还可以卖出股票。因此,是否相应地存在反向学习是一个比较有意义的话题,即基金经理可能通过与投资经验少、专业技能弱的基金经理相反的投资决策以避免亏损。从资产供求角度看,若一只基金被正向学习地越多,则代表其所持有的某只/些股票被购买得越多,注意到机构投资者交易量往往很大,由于交易行为的价格冲击效应会推升股票价格和该基金资产组合价值上升,也使得基金未来业绩更好。反之,若一只基金被反向学习越多,代表其所持有的某只/些股票被卖出得越多,导致该基金资产组合价值下降,也即该基金未来业绩更差。基于上述分析,本文提出假设 1。

H1: 基金学习网络中,单只基金作为被学习者时,被正向学习会提升其业绩,被反向学习会降低其业绩。

基金学习网络中,基金除了被其余基金学习外,其自身也可以主动参与学习。基金的主动学习过程表现出两方面的内涵。一方面,学习的过程是对信息的搜集过程,可以了解更多信息、或者提升已有信息的精度,可能有助于提升业绩。但另一方面,在基于基金持股数据构造的网络中,基金通过网络学习的是其他基金过往的投资行为,而往期投资行为是典型的公共信息。根据 Kacperczyk 和 Seru(2007)的研究,过度地使用公共信息进行投资无法获得超额业绩回报(即无法提高相对其他基金的业绩排名)。从资产供求角度看,学习者相对于被学习者是在下一期买入(卖出)股票,若市场上存在多个学习者同时买入(卖出),则资产价格走高(走低),对该学习者而言其购买成本(卖出价格)则会偏高(偏低),很难给自己带来显著的正收益。综合来看,学习者通过网络进行学习并不一定能提升其业绩。

如果基金通过学习不能提升业绩,基金的主动学习是否有价值呢?对于历史业绩不好的基金来说,需要学习优秀基金的投资行为,尽量让自己的信息跟上行业信息。对于往期能力强的基金而言,可以从另外一个角度来看,也就是如果不学习会有什么后果。往期业绩优秀的基金其目标不仅仅是获得绝对的业绩排名优势,同时也需要保证自己业绩的稳定性(不出现大规模业绩下滑)。往期业绩越好的基金实现业绩稳定增长越困难,因此其需要进行外部学习,综合外部信息和自身收集到的信息进行投资决策。更进一步来看,基金的能力也并非一成不变,市场上很少存在业绩恒强的基金,每只基金的私有信息总是有限的。对基金经理来说,若不进行任何层面的学习,不充分利用可获得的各类信息,其业绩更有可能面临倒退。因此,本文认为市场上所有的基金都需要进行外部学习,其进行外部学习的动机是为了稳定相对自己过去的业绩,避免业绩大幅下滑。据此,提出本文假设 2。

H2: 基金学习网络中,单只基金作为学习者时,正向学习和反向学习与其业绩之间没有显著关系;但基金主动学习可以稳定相对自己过去的业绩,使得自身业绩不倒退。

三、样本数据与研究设计

(一) 数据选取

本文以 WIND 数据库^①中划分的股票型及偏股混合型基金为研究对象。由于被动型基金以跟踪指数为目标,与基金管理者主动管理水平无关,所以剔除样本中的指数型等被动型基金。建立学习网络需要计算基金持仓变化,为准确计算这一变量,本文搜集了基金半年报、年报的全部持仓明细,以及一、三季报的十大重仓股持仓明细^②。由于基金持仓数据从 2005 年始披露才相对完善,因此本文将样本区间设为 2005 年 1 月至 2017 年 12 月。本文主要关注投资于国内 A 股市场的基金,因此剔除了沪港通基金和投资于海外的 QDII 基金。为降低网络构建中的误差,本文要求样本基金持股数量不低于 10 只且持股市值占总资产 50% 以上。为计算业绩和建立 LASSO 模型,还要求样本内基金至少有 2 年的历史持仓数据。通过以上步骤,最终样本为 568 只基金、12160 个观测的非平衡面板数据。本文除了基金类型划分数据来自 WIND 数据库,其余数据例如基金持仓、基金净值、基金规模、基金经理相关特征等均来自 CSMAR 数据库^③。

(二) 学习网络的构建

根据 Bala 和 Goyal(2001) 对于个体选择的理论研究,个体会依据自身经验并吸取其他个体的经验来综合做出决策。对基金来说,即意味着其投资行为一方面会受到自己往期投资行为的影响,另一方面还会受到市场上其余基金往期投资行为的影响。因此,本文考虑如下学习模型:

$$Y_{ik,t} = \mu_i + \sum_{j=1, j \neq i}^{m_t} \rho_{ij} Y_{jk,t-1} + \gamma_i Y_{ik,t-1} + \varepsilon_{i,t} \quad (1)$$

其中, $Y_{ik,t}$ 表示基金 i 从 $t-1$ 期末到 t 期末对股票 k 持仓比例的变化值。 $Y_{ik,t}$ 的具体计算过程随后。首先将 t 期末基金 i 对股票 k 的持仓股数减去 $t-1$ 期末基金 i 对股票 k 的持仓股数,得到变动股数。考虑到相同股数变动对不同规模基金的意义不同,本文参考 Hong 等(2005),将变动股数乘以股票 t 期初的股份得到变动金额,然后将变动金额除以基金 t 期初的持仓总市值,最终得到基金 i 从 $t-1$ 期末到 t 期末对股票 k 的变动比例 $Y_{ik,t}$ 。 $j = 1 \cdots m_t$, m_t 为 t 期市场上的基金数量。

式(1)表示,对于基金 i ,在 t 期的股票持仓变化取决于自己过去的信息 $Y_{ik,t-1}$ 以及从外界学习到的信息 $Y_{jk,t-1}$ 。若 $\rho_{ij} = 0$ 说明基金 i 在 t 期的行为(即持仓)和基金 j 在 $t-1$ 期的行为(即持仓)没有相关性,即基金 i 没有向基金 j 学习;若 $\rho_{ij} \neq 0$ 则表示基金 j 在 $t-1$ 期的行为可以预测基金 i 在 t 期的行为,即基金 i 在 t 期向基金 j 在 $t-1$ 期的行为进行了学习。特别地,若 $\rho_{ij} > 0$,表示行为相似,即基金 i 在 t 期向基金 j 在 $t-1$ 期的行为进行了正向学习(如增持 j 所增持的股票);若 $\rho_{ij} < 0$ 表示行为相反,即基金 i 向基金 j 进行了反向学习(如减持 j 所增持的股票)^④。

根据上文分析,识别出真实的学习网络也就等价于识别出式(1)中哪些 ρ_{ij} 为 0。Tibshirani

① WIND 数据库网址: www.wind.com.cn。

② 由于基金一、三季度只公布前十大重仓股明细,而二、四季度公布全部持仓明细,为尽可能准确刻画基金持仓行为变化,遵循现有关于基金网络的研究中对基金数据的处理方法,本文采取以季报披露的重仓股为重仓股种类基准计算持股比例变动的方法。

③ CSMAR 数据库网址: www.gtarsc.com。

④ ρ_{ij} 表示基金 j 每单位的行为(即持仓)变化可以预测基金 i 下季度 ρ_{ij} 单位的行为(即持仓)变化,其绝对值越大表明基金 j 行为对基金 i 行为的预测能力越强。本文仅仅关注 ρ_{ij} 的符号及显著性,而并未关注其具体数值大小,这是因为网络指标的构造需要利用不同回归方程系数,但不同回归方程系数不具备可比性。

(1996) 提出的 LASSO 方法可以很好地解决这一识别问题。为此,在估计系数时本文使用式(2)的 LASSO 最优化问题:

$$\hat{\mu}_i, \hat{\rho}_{ij}, \hat{\gamma}_i = \arg \min_{\mu_i, \rho_{ij}, \gamma_i} \left\{ \sum_{k=1}^{10} (Y_{ik,t} - \mu_i - \sum_{j=1, j \neq i}^{m_t} \rho_{ij} Y_{jk,t-1} - \gamma_i Y_{ik,t-1})^2 + \lambda_t \sum_{j=1, j \neq i}^{m_t} |\rho_{ij}| \right\} \quad (2)$$

式(2)的 LASSO 回归模型通过对式(1)的回归系数施加线性惩罚项来进行变量筛选。为了增加 LASSO 回归的稳定性,本文参考 Chinco 等(2019)的做法,通过将样本在短期内进行累加的方式增大样本量。这种做法的合理之处在于学习是持续性的,所以应当考虑一段时期内的基金持仓行为。最终形成式(3)的估计模型:

$$\hat{\mu}_i, \hat{\rho}_{ij}, \hat{\gamma}_i = \arg \min_{\mu_i, \rho_{ij}, \gamma_i} \left\{ \frac{1}{L} \sum_{h=0}^{L-1} \sum_{k=1}^{10} (Y_{ik,t-h} - \mu_i - \sum_{j=1, j \neq i}^{m_t} \rho_{ij} Y_{jk,t-h-1} - \gamma_i Y_{ik,t-h-1})^2 + \lambda_t \sum_{j=1, j \neq i}^{m_t} |\rho_{ij}| \right\} \quad (3)$$

其中, L 为估计时间窗口,本文选取 1.5 年的持仓变化记录,也即令 L 为 6。最终对于每只基金,在每个时间点,本文会使用 60 个样本估计 $m_t + 2$ 个参数。注意到,在对式(3)的估计当中,会涉及到对调优参数 λ_t 的选择。根据 Hastie 等(2009)的建议,本文分别采用 AIC、BIC、GCV 以及 CV 准则来进行选择^①。

在 t 期,对于基金 i ,估计出式(3)后,可以构建基金 i 的主动学习网络。基金 i (模型中的被解释变量)在 t 期的整体学习规模为: $\sum_{j=1, j \neq i}^{m_t} I(\rho_{ij,t} \neq 0)$ ^②,也即式(1)排除截距项后非 0 解释变量的个数。特别地,其正入度(Positive In Degree, PID)为 $\sum_{j=1, j \neq i}^{m_t} I(\rho_{ij,t} > 0)$ 反映基金 i 作为学习者向基金 j 进行正向学习的程度;其反入度(Negative In Degree, NID)为 $\sum_{j=1, j \neq i}^{m_t} I(\rho_{ij,t} < 0)$, 反映基金 i 作为学习者向 j 反向学习的程度。

在 t 期,针对市场上每一个基金,均可以估计出相应的式(3)。此时,通过统计基金 i 作为解释变量时,也即在其余基金的 LASSO 回归方程中,基金 i 前系数非 0 的个数,可以定义基金 i 作为被学习者时的整体网络规模。特别地,定义基金 i 的正出度(Positive Out Degree, POD)为 $\sum_{j=1, j \neq i}^{m_t} I(\rho_{ji,t} > 0)$, 反映基金 i 作为被学习者被正向学习的程度;定义反出度(Negative Out Degree, NOD)为 $\sum_{j=1, j \neq i}^{m_t} I(\rho_{ji,t} < 0)$, 反映基金 i 作为被学习者被反向学习的程度。由于本文分别采用 AIC、BIC、GCV、CV4 种准则来选择调优参数,因此会形成 4 组学习网络度量指标,本文分别以前标进行区分,例如采用 AIC 准则判定的指标记作 AIC_PID、AIC_NID、AIC_POD 以及 AIC_NOD。

为方便理解,本文举一个简单的例子来介绍这种网络构建技术。假设市场上 t 期有 A、B、C、D、E、F 6 只基金,对 6 只基金分别建立式(3)的 LASSO 回归模型,假定最终回归结果如下: A 通过 LASSO 从 B、C、D、E、F 中选择出 B、C、E、F,其中 C 系数为负,其余均为正; B 通过 LASSO 从 A、C、D、E、F 中选择出 A、C、D,其中 A、D 系数为负, C 为正; C 从 A、B、D、E、F 中选择出 E,其系数为负; D 从 A、B、C、E、F 中选择出 A,其系数为正; E 从 A、B、C、D、F 中选择出 B、C、F,其中 B 系数为正,其

① 因篇幅所限,模型(3)估计及各准则计算方式以附件展示,见《统计研究》网站所列附件。下同。

② 其中, I 为示性函数,若括号内不等式成立其值为 1, 否则为 0。

余均为负; F 从 A、B、C、D、E 中选择出 C, 其系数为正。则据此可以形成如附图 1 所示网络^①。附图 1 中红色箭头表示负系数形成的连接, 蓝色箭头表示正系数形成的连接。以 A 为例, 其 PID 为 3, NID 为 1, POD 为 1, NOD 为 1。

前文分析中本文论述了建立有向网络在经济上的必要性。然而在真实市场中, 无向网络和有向网络间的差异有多大? 在附图 2 中本文根据华夏红利混合基金(代码: 2011) 在 2007 年 1 季度的持仓数据, 参考 Pareek(2012) 的做法, 建立了基金间的 5% 共同持股网络, 发现其网络度为 37。而在根据 LASSO 方法建立的学习网络中, 当华夏红利混合作为学习者时, 其反向学习度(即反入度 NID) 为 10, 正向学习度(即正入度 PID) 为 4; 当其作为被学习者时, 反向学习度(即反出度 NOD) 为 7, 正向学习度(即正出度 POD) 为 3。由此可见, 学习网络的规模远远小于共同持股网络的规模, 且学习网络中不同方向的网络度数值存在明显差异。而从两类网络中的基金代码可以看出, 两类网络所包含的基金大多相似, 即学习网络当中的基金大都来自于共同持股网络中的基金。这意味着根据 Pareek 方法构建的无向网络中包含噪音, 将其拓展为有向网络(即 LASSO 方法建立的学习网络)是有必要的。

(三) 变量说明

1. 基金业绩。

本文采用多因子模型对基金净值收益率进行风险调整, 得到风险调整收益率 Alpha。以 Carhart4 因子调整计算为例, 其构建方法如下:

$$R_{j,s} - r_{f,s} = \hat{\alpha}_{j,t-1} + \sum_{k=1}^4 \hat{\beta}_{k,t-1} F_{k,s} + \varepsilon_{j,s}, s = t - 24, \dots, t - 1 \quad (4)$$

$$\alpha_{j,t} = R_{j,t} - \sum_{k=1}^4 \hat{\beta}_{k,t-1} F_{k,t} \quad (5)$$

其中, $R_{j,s}$ 表示基金 j 在 s 月的复权净值收益率, $r_{f,s}$ 为 s 月的无风险收益率, F 代表月度 4 因子(市场风险溢价因子、市值因子、账面市值因子、动量因子)。参考 Agarwal 等(2015), 在每个月计算基金业绩时, 本文首先用基金 j 的前 24 个月的月收益率进行式(4)回归, 计算出 4 个因子参数值, 然后带入式(5)计算出基金当月的风险调整收益率。按上述方法计算出每只基金每个月的风险调整收益率之后, 在季度层面进行平均化处理, 得到基金每季度的月均风险调整收益率。为便于直观解释, 本文又将该月均风险调整收益率进行年化处理。

2. 控制变量。

参考 Kacperczyk 和 Seru(2007) 对基金业绩的研究, 本文从基金特征层面和基金经理层面选取了影响基金业绩的如下控制变量^②。基金特征变量包括: 基金规模(Size)、基金家族规模(Fsize)、基金年龄(Age)、基金收益率波动率(Std)、基金管理费(FeeRatio)、基金历史业绩(LagRt)、上季度基金分红大小(Divid)。基金经理特征变量包括: 基金经理学历虚拟变量(PHD)、基金经理性别虚拟变量(Gender)、基金管理团队规模(TeamSize)。

3. 描述统计。

表 1 给出了本文涉及到的主要变量描述统计。从中可以看出, 样本中的基金平均 Alpha 为正, 表明国内基金平均来看具有一定的技能, 该结果与大多数国内文献相一致(如罗荣华等, 2011)。本文构建的学习网络的平均规模为 11 左右(正向学习度加反向学习度), 其中反向学习度要大于正向学习度。以 AIC 准则下的判定为例, 对于学习者, 其反向学习度数值(AIC_NID) 为 7.002, 而正向学习度平均数值(AIC_PID) 为 3.897, 约占反向学习度数值的一半。

① 因篇幅所限, 本文未汇报的网络以附图 1~2 展示。

② 因篇幅所限, 控制变量定义以附表 1 展示。

表 1 变量描述统计

	变量名称	平均数	中位数	最小值	最大值	标准差
业绩(%)	CAPM Alpha	5.356	2.623	-213.555	378.751	29.823
	3F Alpha	3.980	2.395	-200.670	383.625	27.465
	4F Alpha	1.832	0.653	-203.068	394.273	26.912
学习网络(个)	AIC_POD	3.823	3.000	0.000	27.000	3.259
	AIC_NOD	6.816	6.816	0.000	49.000	4.771
	AIC_PID	3.897	1.000	0.000	30.000	5.482
	AIC_NID	7.002	3.000	0.000	48.000	8.327
	BIC_POD	0.312	0.000	0.000	9.000	0.654
	BIC_NOD	0.743	0.000	0.000	12.000	1.124
	BIC_PID	0.322	0.000	0.000	20.000	1.443
	BIC_NID	0.769	0.000	0.000	31.000	2.473
	GCV_POD	1.447	1.000	0.000	15.000	1.604
	GCV_NOD	3.233	3.000	0.000	26.000	2.707
	GCV_PID	1.473	0.000	0.000	51.000	3.447
	GCV_NID	3.306	1.000	0.000	55.000	5.752
	CV_POD	2.735	2.000	0.000	20.000	2.256
	CV_NOD	6.018	5.000	0.000	27.000	3.692
	CV_PID	3.569	2.000	0.000	39.000	4.299
	CV_NID	7.243	4.000	0.000	53.000	7.689
控制变量	Size	29.056	16.494	0.054	447.354	36.769
	Fsize	213.525	167.172	0.469	1330.000	186.037
	Age	73.930	67.630	44.700	197.930	35.037
	Return(%)	41.102	25.591	-535.876	1228.241	171.493
	Std	1.602	1.323	0.106	23.846	1.131
	Divd	0.017	0.000	0.000	3.100	0.102
	FeeRatio	1.495	1.500	0.330	2.000	0.066
	TeamSize	1.925	2.000	0.000	6.000	0.831
	Gender	0.750	1.000	0.000	1.000	0.433
	PHD	0.2117	0.000	0.000	1.000	0.409

四、实证结果

(一) 基准回归

为检验学习网络和基金业绩关系,本文首先建立如式(6)所示的单变量双向固定效应面板回归模型:

$$Alpha_{i,t} = \alpha + \beta Degree_{i,t} + u_i + v_t + \varepsilon_{i,t} \quad (6)$$

其中, $Alpha_{i,t}$ 代表 t 季度基金 i 的以 CAPM 单因子、Fama-French 3 因子以及 Carhart 4 因子计算所得的月均风险调整收益率。 $Degree_{i,t}$ 代表基金 i 在 t 季度的网络度数值^①。 u_i 表示个体固定效应, v_t 表示时间固定效应。根据上文所述的网络建立方式,共有 4 种形式的网络度(POD、PID、NOD、NID),在式(6)中本文统一使用 $Degree$ 表示。回归结果如表 2~5 所示^②。

表 2 汇报了当基金作为被学习者时的正出度与其业绩的关系,表中的每个值为不同回归模型下的回归结果。可以看出,在所有的准则以及业绩衡量标准下,回归系数符号均为正且大部分都显

① 为方便介绍本文将公式中的网络度标注为 t 期,但要注意的是,在学习网络中,学习的对象为上一期的持仓变动,本文统计的也是上一期有相似行为的基金个数,因此该方程实际上指的是学习到的上一期的信息对下一期业绩的影响,下文的所有回归方程时间标识与此类似。

② 本文所有的回归表格均采用双向固定效应,回归系数的标准差在基金层面聚类。“*”“**”和“***”分别表示回归系数在 10%、5% 和 1% 的水平显著不等于 0。

表 2 被学者的正向学习: 正出度 (POD) 与基金业绩的关系

	AIC 准则 (1)	BIC 准则 (2)	GCV 准则 (3)	CV 准则 (4)
CAPM	0.297*** (3.88)	0.094 (0.22)	0.183 (1.18)	0.317*** (3.07)
3F	0.319*** (4.63)	0.567* (1.85)	0.173 (1.32)	0.176* (1.88)
4F	0.319*** (4.62)	0.755** (2.45)	0.268** (2.05)	0.267*** (2.81)

著,验证了假设 1 中前半部分所预期的: 对学习网络中的被学习者而言,向其正向学习的其他基金越多,该基金的业绩越高。以第一行第一列的回归结果为例,当采用 AIC 准则来进行 LASSO 回归确定网络度,以 CAPM 模型计算风险调整收益率时,被学习基金的学习者每增加一个(也即一单位正出度的提升)可以显著提升被学习基金年化风险调整收益率 0.297%。对于被学习者来说,正出度 POD 越大业绩之所以提升,一个可能的原因是被学习基金的某只/些持仓股票被正向学习得越多,会使得这只/些股票被买入得更多,从而推高股票的市场价格,进而提升已持有这只/些股票的基金下期业绩。

表 3 被学习者的反向学习: 负出度 (NOD) 与基金业绩的关系

	AIC 准则 (1)	BIC 准则 (2)	GCV 准则 (3)	CV 准则 (4)
CAPM	-0.117** (-1.96)	-0.636*** (-3.46)	-0.149* (-1.65)	-0.007 (-0.10)
3F	-0.155*** (-2.55)	-0.599*** (-3.38)	-0.202** (-2.20)	-0.145* (-1.94)
4F	-0.133** (-2.21)	-0.649*** (-3.60)	-0.213** (-2.30)	-0.138* (-1.78)

表 3 展示了学习网络中被学习基金的负出度与其业绩的关系。可以看出,在所有的准则以及业绩衡量标准下,回归系数符号均为负数且基本显著,验证了假设 1 中后半部分所预期的: 对学习网络中的被学习者而言,向其反向学习的其他基金越多,该基金的业绩越差。对于被学习者来说,负出度 NOD 越大,业绩之所以下降,可能的原因是某只/些持仓股票被卖出得多,考虑到基金作为机构投资者往往交易量比较大,其交易行为对价格的冲击作用不容忽视,从而使得这只/些股票价格下降,导致已持有这只/些股票的基金下期业绩下降。

表 4 学习者的正向学习: 正入度 (PID) 与基金业绩的关系

	AIC 准则 (1)	BIC 准则 (2)	GCV 准则 (3)	CV 准则 (4)
CAPM	-0.021 (-0.52)	-0.108 (-0.77)	-0.057 (-0.97)	-0.030 (-0.63)
3F	0.036 (0.95)	0.006 (0.04)	-0.036 (-0.66)	-0.036 (-0.75)
4F	0.012 (0.29)	-0.081 (-0.56)	-0.036 (-0.65)	-0.028 (-0.55)

表 5 学习者的反向学习: 负入度 (NID) 与基金业绩的关系

	AIC 准则 (1)	BIC 准则 (2)	GCV 准则 (3)	CV 准则 (4)
CAPM	0.001 (0.03)	-0.012 (-0.13)	0.005 (0.14)	-0.007 (-0.24)
3F	0.026 (0.99)	0.040 (0.48)	0.017 (0.50)	-0.032 (-1.16)
4F	0.015 (0.55)	0.025 (0.28)	0.021 (0.63)	-0.032 (-1.06)

表 4 和表 5 分别代表当基金作为学习者时的正向学习和反向学习与其业绩的关系。从回归结果可以看出,正向学习、反向学习均不能取得明显业绩优势。可能的原因在于,基金经理在网络中所学习的其他基金的持仓信息是历史信息也即公共信息,而过度使用公共信息的投资往往会导致较差的业绩排名。因此,尽管基金经理通过学习可能提高了自己的信息精度,更有利于做出投资决策,但基于公共信息投资给基金业绩带来的负面影响冲销了信息精度所带来的正面影响。从学习后交易导致的资产价格变动来看,由于学习考察的是网络中的往期信息,假设基金进行正向学习,而市场上往往有多个正向学习者,则在该基金买入股票时,可能股票价格已经处于相对较高的价位,较高的购入成本使得学习不一定能够提升该学习者基金的投资组合收益。

(二) 进一步分析

上一节本文考虑了在不同业绩测量标准下,不同网络指标与业绩的单变量关系。为控制其他时变因素对于基金业绩的影响,本节进一步在式(6)中加入第三部分所列出的控制变量,估计如式(7)的方程。因篇幅所限,本文仅汇报以 Carhart 4 因子调整后的业绩指标为被解释变量,POD 为解释变量的结果。

$$\begin{aligned} \text{Alpha}_{i,t} = & \alpha + \beta_1 \text{Degree}_{i,t} + \beta_2 \text{LagRt}_{i,t-1} + \beta_3 \text{Size}_{i,t-1} + \beta_4 \text{Fsize}_{i,t-1} + \beta_5 \text{Std}_{i,t-1} + \beta_6 \text{Divd}_{i,t-1} \\ & + \beta_7 \text{FeeRatio}_{i,t-1} + \beta_8 \text{TeamSize}_{i,t} + \beta_9 \text{Gender}_{i,t} + \beta_{10} \text{PHD}_{i,t} + u_i + v_t + \varepsilon_{i,t} \end{aligned} \quad (7)$$

总体来看,包含控制变量的回归结果与单变量回归结果保持一致。如表 6 所示,对于被学习者而言,向其正向学习的基金越多,其越可能获得正的风险调整收益。在有关基金特征的控制变量中,基金规模和基金管理费率的系数均显著为负,与已有文献一致。本文并未发现基金家族规模和基金分红对基金业绩有显著影响。基金管理团队规模的系数显著为负,表明多个基金经理共同管理不仅未能提升基金业绩,反而可能由于协调摩擦或免费搭车等因素而使得基金业绩表现变差。同样地,未汇报的被反向学习以及主动学习者控制变量回归结果仍与单变量回归结果一致^①。

前述数据结果得出的基本结论是:单只基金作为被学习者时,被正向学习会提升其业绩,被反向学习会降低其业绩。考虑到基金作为被学习者时,其他基金的正向学习和反向学习同时存在,有可能使得被学习的效应相互抵消,为此本文构建反映基金被净正向学习的指标(POD-NOD),该值越大表明该基金被净正向学习的程度越大。同时,考虑到基金被学习的同时会主动参与学习,基金的主动学习也会干扰基金被学习对其业绩的影响。因此,本文又在模型中加入总学习程度(PID+NID)以控制基金当期主动学习的影响,建立式(8)的净学习效应赛马模型。

本文还在基本回归模型中同时加入 4 种形式的学习模式(POD、NOD、PID、NID),建立式(9)的赛马模型,基于该模型的结果也更容易检验学习模式与基金业绩之间的关系。

$$\text{Alpha}_{i,t} = \alpha + \beta_1 (\text{POD}_{i,t} - \text{NOD}_{i,t}) + \beta_2 (\text{PID}_{i,t} + \beta_4 \text{NID}_{i,t}) + \gamma X_{\text{control}} + \varepsilon_{i,t} \quad (8)$$

$$\text{Alpha}_{i,t} = \alpha + \beta_1 \text{POD}_{i,t} + \beta_2 \text{NOD}_{i,t} + \beta_3 \text{PID}_{i,t} + \beta_4 \text{NID}_{i,t} + \gamma X_{\text{control}} + \varepsilon_{i,t} \quad (9)$$

两类赛马模型回归结果如表 7 所示。表 7 的偶数列式为(8)回归结果,奇数列式为(9)回归结果。以 CV 准则下结果为例,第(7)列的数据结果表明:同时考虑 4 种学习模式,被正向学习仍然显著提升基金业绩,被反向学习也仍然显著降低基金业绩,而主动学习仍然和业绩没有显著关系。检验净学习效应的第(8)列数据结果表明基金被净正向学习程度(POD-NOD)越大,其业绩越好。该变量回归系数的 t 统计量为 3.41,高于第(7)列中仅考虑被正向学习(POD)回归系数的 t 统计量(2.96),表明考虑学习效果可能相互抵消的赛马模型回归结果更加稳健。

^① 因篇幅所限,NOD、PID、NID 控制变量回归结果以附表 2~4 展示。

表 6 被学者的正向学习: 正出度 (POD) 与基金业绩的关系

	AIC 准则 (1)	BIC 准则 (2)	GCV 准则 (3)	CV 准则 (4)
POD	0.351*** (4.98)	0.785** (2.54)	0.332** (2.50)	0.326*** (3.33)
LagRt	-0.026*** (-4.55)	-0.025*** (-4.47)	-0.026*** (-4.50)	-0.026*** (-4.54)
Size	-4.132*** (-6.91)	-4.122*** (-6.92)	-4.135*** (-6.93)	-4.128*** (-6.90)
Fsize	0.299 (0.29)	0.350 (0.34)	0.341 (0.33)	0.309 (0.30)
Age	0.984 (0.42)	0.943 (0.40)	0.990 (0.42)	1.080 (0.46)
Std	-0.309 (-1.20)	-0.331 (-1.28)	-0.330 (-1.28)	-0.332 (-1.28)
Divd	-3.052 (-1.46)	-3.106 (-1.48)	-3.087 (-1.47)	-3.101 (-1.48)
FeeRatio	-27.108*** (-2.99)	-26.660*** (-2.89)	-26.948*** (-2.99)	-27.682*** (-3.07)
Gender	-0.243 (-0.19)	-0.222 (-0.17)	-0.254 (-0.20)	-0.240 (-0.19)
PHD	-0.288 (-0.28)	-0.250 (-0.24)	-0.250 (-0.24)	-0.306 (-0.29)
TeamSize	-0.863* (-1.86)	-0.874* (-1.89)	-0.876* (-1.89)	-0.868* (-1.87)
时间固定	是	是	是	是
个体固定	是	是	是	是
调整 R ²	0.242	0.241	0.241	0.241
样本数	12160	12160	12160	12160
基金数	568	568	568	568

表 7 赛马模型的实证结果

	AIC		BIC		GCV		CV	
	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
POD	0.325*** (4.53)		0.702** (2.25)		0.286** (2.11)		0.293*** (2.96)	
NOD	-0.148** (-2.33)		-0.682*** (-3.70)		-0.238** (-2.44)		-0.162** (-2.00)	
PID	-0.036 (-0.54)		-0.330 (-1.46)		-0.219 (-1.24)		0.022 (0.29)	
NID	0.041 (0.92)		0.210 (1.44)		0.147** (2.41)		-0.043 (-0.95)	
POD-NOD		0.207*** (4.65)		0.691*** (4.76)		0.254*** (3.55)		0.202*** (3.41)
PID+NID		0.012 (0.69)		0.016 (0.28)		0.014 (0.62)		-0.021 (-1.02)
控制变量	是	是	是	是	是	是	是	是
时间固定	是	是	是	是	是	是	是	是
个体固定	是	是	是	是	是	是	是	是
调整 R ²	0.290	0.289	0.289	0.289	0.289	0.289	0.289	0.289
样本数	12160	12160	12160	12160	12160	12160	12160	12160
基金数	568	568	568	568	568	568	568	568

为直观对比基金被学习以及学习的业绩差异,本文以 $POD-NOD>0$ 为被净正向学习组, $POD-NOD<0$ 为被净反向学习组,对比两组业绩(4F Alpha)发现被净正向学习组的业绩显著优于被净反

向学习组。以总学习规模(PID+NID)前 50%为高学习组,后 50%为低学习组,对比发现两组业绩无显著差异。

本文同时采用 AIC、BIC、GCV、CV 准则进行调优参数的选择。根据 Hastie 等(2009)以及 Le (2020),在大样本情形下,BIC 效果优于 AIC。但若样本规模较小,BIC 会造成过度压缩,AIC 反而可以选择出“恰当模型”。本文每个基金 LASSO 估计方程的样本量为 60,相对较小,为此 AIC 准则的可靠性强于 BIC。与此同时,GCV 准则中对自由度分布的估计依赖于样本量,在小样本情况下其可信度也低于 AIC。接着,根据各准则下构建学习网络规模大小进行判断,本文认为在进行基金业绩分析时,AIC 准则与 CV 准则的可靠性相似,GCV 准则的可靠性次之,BIC 准则的可靠性则最低。值得注意的是,即使 GCV、BIC 准则的可信度低于 AIC 及 CV,但回归结果中,GCV 与 BIC 的结果与 AIC、CV 也趋于一致,这是由于 GCV、BIC 虽然存在系数过度压缩问题,但两者也均识别出了最重要的学习行为连接,其回归结果也具有参考性。

五、学习动机分析

前面的结果表明,基金间的学习行为对学习双方具有差异化的影响:对被学习者来说,被正向学习越多,该基金越可能获得正的风险调整收益、业绩越好,被反向学习越多,则业绩越差。然而作为学习的发起者,若学习并不能获取绝对风险调整正收益,那么基金主动进行学习的动机是什么?该部分将进一步探讨基金主动学习为其带来的业绩增量也即相对自己过去业绩的变化。

假设若某只基金不进行任何方向学习,则其持仓行为与上一期保持一致。基于此,本文可以模拟一只不学习的基金并计算其保持上一期持仓时的本期组合模拟收益率,然后将基金当期实际收益率减去模拟收益率,记为业绩增量 $\Delta Performance$,表示学习给基金带来的业绩提升,并建立如式(10)的回归模型:

$$\Delta Performance_{i,t} = \alpha + \beta Degree_{i,t} + \gamma Control + u_i + v_t + \varepsilon_{i,t} \quad (10)$$

式(10)中的控制变量与式(7)保持一致。考虑到 CV 准则无需估计样本自由度,受样本规模影响较小,且其在实际中应用较多,本文以 CV 准则确定的网络度结果进行学习动机分析,回归结果如表 8 所示。

表 8 学习者学习行为与业绩增量

	(1)	(2)	(3)	(4)	(5)	(6)	(7)
NID+PID	0.267** (2.10)			0.276** (2.18)			
NID		0.436** (2.28)			0.447** (2.34)		0.583** (2.01)
PID			0.457 (1.45)			0.485 (1.54)	-0.317 (-0.66)
POD&NOD	否	否	否	是	是	是	是
控制变量	是	是	是	是	是	是	是
时间固定	是	是	是	是	是	是	是
个体固定	是	是	是	是	是	是	是
调整 R ²	0.217	0.217	0.217	0.219	0.219	0.218	0.219
样本数	12160	12160	12160	12160	12160	12160	12160
基金数	568	568	568	568	568	568	568

表 8 中第(1)列的回归结果表明,整体网络度越大,基金越能获得学习带来的业绩增长,即若基金不进行任何学习,其业绩会变差。第(2)、(3)列区分了正向学习和反向学习,两个模型中网络度回归系数均为正,且反入度系数显著,正入度系数接近显著。第(4)~(7)列的回归结果显示在

控制基金被学习情况后,基金的主动学习相较于不学习仍可以提高其相对自身往期的业绩。进一步,第(5)~(7)列的结果表明主动学习带来的相对自身往期业绩的提升主要来自于反向学习。

表 8 的回归结果表明基金的主动学习可以提升相对自身历史业绩的增长,而其中又以反向学习对业绩增长的影响显著。鲁臻和邹恒甫(2007)的研究表明成交量大的股票更易发生反转。从表 1 的描述性统计可以看出,市场上反向学习的规模远大于正向学习,反向学习的交易规模更大,价格冲击作用更强,基金进行反向学习,购买的上一期收益低的股票更易实现反转,给其带来业绩提升。正向学习的效果并不显著,原因可能在于:若正向学习可以带来短期业绩提升,则很有可能是通过股票动量效应带来的业绩提升。然而,Liu 等(2019)的研究表明,我国股票市场不存在动量效应。同时正向学习可以视作一种主动抱团行为,其有利于降低基金所承担的异质风险,本文以 4 因子回归模型下的残差标准差代理基金所承担的异质风险,附表 5 的结果显示基金的正向学习可能降低其所承担的特质风险^①。同时正向学习也可能存在一些其他价值,如:市场上存在基本面投资者,若成为其追随者,意味着长期业绩提升。

六、稳健性检验

本文采用 LASSO 算法建立了基金间的学习网络。这种构建方式的一个潜在问题是,即使某只基金 j 的持仓变化对基金 i 的持仓变化有好的预测能力,也不一定代表基金 i 向基金 j 进行了学习。这一点可以从表 2 的单变量回归结果中看出:在不同准则和不同风险调整业绩下回归系数的差异较大。但反过来,若现实中基金 i 确实向基金 j 进行学习,则基金 j 会是基金 i 一个好的统计预测因子,即使在不同准则和不同业绩风险调整标准下,回归系数也应当保持稳定。为了增强 LASSO 模型的经济含义,本文在稳健性部分采取投票机制确定学习网络,具体随后:若学习网络中的某条学习连接在 AIC、BIC、GCV、CV4 种准则判断下有 3 个及以上的准则认定该连接存在,本文才认为两基金间存在学习行为。本文将投票机制下相应的网络度数值变量分别记为 Vote POD、Vote NOD、Vote PID、Vote NID,并以这 4 个指标分别建立式(7)的面板回归模型,结果如表 9 和表 10 所示。

表 9 被学习者的稳健性检验

	CAPM (1)	3-F (2)	4-F (3)	CAPM (4)	3-F (5)	4-F (6)
Vote POD	0.539*** (2.82)	0.448*** (2.63)	0.448*** (2.58)			
Vote NOD				-0.352** (-2.19)	-0.388** (-2.45)	-0.332** (-2.10)
控制变量	是	是	是	是	是	是
时间固定	是	是	是	是	是	是
个体固定	是	是	是	是	是	是
调整 R ²	0.360	0.298	0.241	0.359	0.297	0.240
样本数	12160	12160	12160	12160	12160	12160
基金数	568	568	568	568	568	568

通过建立投票机制,本文发现,对于被学习者而言,正出度 POD 与业绩之间的关系仍然显著为正:以 CAPM 风险调整业绩时,向被学习者学习的基金数量每增加一个,会带来 0.539% 的基金年化风险调整收益,POD 的估计值在 Fama-French 3 因子模型中为 0.448,4 因子模型中仍为 0.448,回归系数大小比较稳定。因此,本文可以认为对被学习基金而言,1 单位来自其他基金的正向学习可以为其带来 0.448%~0.539% 的年化风险调整收益。相应地,1 单位来自其他基金的反向学习会

^① 因篇幅所限,特质风险的结果以附表 5 展示。

表 10 学习者的稳健性检验

	CAPM (1)	3-F (2)	4-F (3)	CAPM (4)	3-F (5)	4-F (6)
Vote PID	-0. 033 (-0. 30)	0. 008 (0. 08)	0. 006 (0. 06)			
Vote NID				0. 057 (0. 74)	0. 103 (1. 37)	0. 099 (1. 30)
控制变量	是	是	是	是	是	是
时间固定	是	是	是	是	是	是
个体固定	是	是	是	是	是	是
调整 R ²	0. 359	0. 297	0. 240	0. 359	0. 297	0. 240
样本数	12160	12160	12160	12160	12160	12160
基金数	568	568	568	568	568	568

给被学习者带来-0. 332%~-0. 388%年化风险调整收益。在表 10 中,对于学习者的稳健性检验和之前的结果保持一致,且随着采用单因子、3 因子和 4 因子调整业绩,回归模型的 R² 逐步降低,但是学习网络度回归系数的显著性保持不变。

七、结论

本文以我国 2005 年至 2017 年的开放式主动管理型基金的季度持股数据,结合 LASSO 算法构建了动态、有向的基金学习网络,分别从学习者和被学习者的角度分析了学习网络对基金业绩的影响。本文的实证分析发现基金间存在正向学习与反向学习两种行为模式,且两种模式的效果存在差异:当基金作为被学习者时,被正向学习越多,业绩越好,被反向学习越多,业绩越差;当基金作为主动学习者时,主动学习与基金绝对业绩无明显关联,但学习有助于获得相对自身历史业绩的优势,保证“不掉队”。

本文的分析结果表明基金经理要想取得绝对业绩优势还是需要依靠自身的管理水平。基金经理可以通过积极参加调研,提升自己的投资能力。但是对于主动管理水平较低的基金经理来说,基金间的互相学习也为其提供了一种“不掉队”的途径。对于市场监管者来说,如何增强市场有效性,降低基金间互相学习导致的经济后果,促使基金经理积极参与金融市场建设,本文的研究也提供了一个新的视角。对于个体投资者来说,本文所关注的学习网络有助于帮助其更好地理解基金行为机制,挑选出优质基金。

参考文献

- [1] 陈新春,刘阳,罗荣华. 机构投资者信息共享会引来黑天鹅吗? 基金信息网络与极端市场风险 [J]. 金融研究, 2017(7): 140-155.
- [2] 刘京军,苏楚林. 传染的资金基于网络结构的基金资金流量及业绩影响研究 [J]. 管理世界, 2016(1): 54-65.
- [3] 鲁臻,邹恒甫. 中国股市的惯性与反转效应研究 [J]. 经济研究, 2007(9): 145-155.
- [4] 罗荣华,兰伟,杨云红. 基金的主动性管理提升了业绩吗? [J]. 金融研究, 2011(10): 127-139.
- [5] 罗荣华,田正磊. 基金网络、竞争阻隔与股票信息环境 [J]. 中国工业经济, 2020(3): 137-154.
- [6] 申宇,赵静梅,何欣. 校友关系网络、基金投资业绩与小圈子效应 [J]. 经济学(季刊), 2016, 15(1): 403-428.
- [7] 田正磊,罗荣华,刘阳. 信息传递、集体踩踏与系统性尾部风险 [J]. 经济学(季刊), 2019, 18(3): 898-918.
- [8] 肖欣荣,刘建,赵海健. 机构投资者行为的传染: 基于投资者网络视角 [J]. 管理世界, 2012(12): 35-45.
- [9] 张兴祥,钟威,洪永淼. 国民幸福感的指标体系构建与影响因素分析: 基于 LASSO 的筛选方法 [J]. 统计研究, 2018, 35(11): 3-13.
- [10] Agarwal V, Mullally K, Tang Y, et al. Mandatory Portfolio Disclosure, Stock Liquidity, and Mutual Fund Performance [J]. Journal of Finance, 2015, 70(6): 2733-2776.

- [1] Amihud Y, Goyenko R. Mutual Funds R2 as Predictor of Performance [J]. Review of Financial Studies, 2013, 26(3): 667–694.
- [2] Bala V, Goyal S. Conformism and Diversity Under Social Learning [J]. Economic Theory, 2001, 17(1): 101–120.
- [3] Brown K, Harlow W, Starks L. Of Tournaments and Temptations: An Analysis of Managerial Incentives in the Mutual Fund Industry [J]. Journal of Finance, 1996, 51(1): 85–110.
- [4] Chevalier J, Ellison G. Are Some Mutual Fund Managers Better Than Others? Cross Sectional Patterns in Behavior and Performance [J]. Journal of Finance, 1999, 54(3): 875–899.
- [5] Chincio A, Clark J, Ye M. Sparse Signals in the Cross Section of Returns [J]. Journal of Finance, 2019, 74(1): 449–492.
- [6] Choi N, Fedenia M, Skiba H, et al. Portfolio Concentration and Performance of Institutional Investors Worldwide [J]. Journal of Financial Economics, 2017, 123(1): 189–208.
- [7] Cohen L, Frazzini A, Malloy C. The Small World of Investing: Board Connections and Mutual Fund Returns [J]. Political Economy, 2008, 116: 951–979.
- [8] Conley T, Udry C. Learning about a New Technology: Pineapple in Ghana [J]. American Economic Review, 2010, 100(1): 35–69.
- [9] Crawford S, Gray W, Kern A. Why Do Fund Managers Identify and Share Profitable Ideas? [J]. Journal of Financial and Quantitative Analysis, 2017, 52(5): 1903–1926.
- [10] Hastie T, Tibshirani R, Friedman J. The Elements of Statistical Learning: Data Mining, Inference and Prediction [M]. Springer-Verlag, 2009: 1–763.
- [11] Hong H, Kubik J, Stein J. Thy Neighbor's Portfolio: Word of Mouth Effects in the Holdings and Trades of Money Managers [J]. Journal of Finance, 2005, 60(6): 2801–2824.
- [12] Kacperczyk M, Seru A. Fund Manager Use of Public Information: New Evidence on Managerial Skills [J]. Journal of Finance, 2007, 62(2): 485–528.
- [13] Le C. How to Choose Tuning Parameters in Lasso and Ridge Regression [J]. Asian Journal of Economics and Banking, 2020, 4(1): 61–76.
- [14] Lee M, So E. Alphanomics: The Informational Underpinnings of Market Efficiency [M]. Now Publishers Inc, 2015: 1–220.
- [15] Liu J, Stambaugh R, Yuan Y. Size and Value in China [J]. Journal of Financial Economics, 2019, 134(1): 48–69.
- [16] Massa M, Patgiri R. Incentives and Mutual Fund Performance: Higher Performance or Just Higher Risk Taking? [J]. Review of Financial Studies, 2008, 22(5): 1777–1815.
- [17] Pareek A. Information Networks: Implications for Mutual Fund Trading Behavior and Stock Returns [C]. AFA Meeting Paper, 2012.
- [18] Pastor L, Stambaugh R, Taylor L. Do Funds Make More When They Trade More? [J]. Journal of Finance, 2017, 72(4): 1483–1528.
- [19] Pool V, Stoffman N, Yonker S. The People in Your Neighborhood: Social Interactions and Mutual Fund Portfolios [J]. Journal of Finance, 2015, 70(6): 2679–2732.
- [20] Tibshirani R. Regression Shrinkage and Selection Via the Lasso [J]. Journal of the Royal Statistical Society: Series B (Methodological), 1996, 58(1): 267–288.

作者简介

罗荣华,西南财经大学金融学院教授、博士生导师。研究方向为金融计量和资本市场。

赵森杨,西南财经大学金融学院博士研究生。研究方向为金融计量和资本市场。

方红艳(通讯作者),上海对外经贸大学金融管理学院副教授、博士生导师。研究方向为资本市场和公司金融。

电子邮箱: cherry_hyfang@sina.com。

(责任编辑: 张晓梅)